



UFOP

Universidade Federal
de Ouro Preto

CEA055 – Estatística e Probabilidade

Estatística Descritiva I

Objetivos do aula:

- Conhecer os tipos de variáveis e algumas representações gráficas.

Referências:

- Bussab, Morettin. **Estatística Básica**, 9ed — Cap. 2 (2.1 a 2.4) e Cap. 3 (3.1)
- Montgomery, Runger. **Applied Statistics and Probability for Engineers**, 7th ed — Cap. 6 (6.1 a 6.3)
- Magalhães, Lima. **Noções de Probabilidade e Estatística**, 5ed — Cap. 1 (1.2)

Vamos introduzir o conceito de **variável** com um exemplo:

Exemplo: Um pesquisador está interessado em fazer um levantamento sobre alguns aspectos socioeconômicos dos empregados da seção de orçamentos da Companhia MB. Usando informações obtidas do departamento de pessoal, ele elaborou a Tabela 2.1. Essa tabela é chamada planilha de dados.

N	Estado Civil	Grau de Instrução	N de Filhos	Salario (x Sal Min)	Idade (anos)	Idade (Meses)	Região de Procedência
1	solteiro	ensino fundamental		4,00	26	3	interior
2	casado	ensino fundamental	1	4,56	32	10	capital
3	casado	ensino fundamental	2	5,25	36	5	capital
4	solteiro	ensino médio		5,73	20	10	outra
5	solteiro	ensino fundamental		6,26	40	7	outra
6	casado	ensino fundamental	0	6,66	28	0	interior
7	solteiro	ensino fundamental		6,86	41	0	interior
8	solteiro	ensino fundamental		7,39	43	4	capital
9	casado	ensino médio	1	7,59	34	10	capital
10	solteiro	ensino médio		7,44	23	6	outra
11	casado	ensino médio	2	8,12	33	6	interior
12	solteiro	ensino fundamental		8,46	27	11	capital

Variáveis da tabela:


As variáveis podem ser identificadas na primeira linha da tabela.

- Estado Civil, Grau de Instrução, N de Filhos, Salario (x Sal Min), Idade (anos), Idade (Meses), Região de Procedência

Os números referentes a cada variável são chamados de realizações.

- Atribuiremos a cada variável uma letra maiúscula ($X, Y, Z, W, \dots$)

As variáveis se dividem em tipos:



Variáveis qualitativas

- **Nominal**
 - Ex.: cor dos olhos, comida preferida, etc.
- **Ordinal**
 - Grau de escolaridade, patentes do exército, etc.

Algumas variáveis nominais são dicotômicas, ou seja, só podem ocorrer duas realizações (sucesso e fracasso).

Variáveis quantitativas

- **Discreta**
 - Quando as realizações possíveis pertencem a um conjunto finito ou enumerável.
- **Contínua**
 - Quando as realizações pertencem a um intervalo em $\mathbb{R}$.

Distribuições de frequências

- Ao estudarmos uma variável, é importante saber a frequência que suas realizações acontecem.
- Estudar a distribuição de frequências das realizações nos dará uma ideia do comportamento da variável.

Exemplo de tabela de distribuição de frequências

Grau de instrução	Frequência n_i	Proporção f_i	Porcentagem 100 f_i
Fundamental	12	0,3333	33,33
Médio	18	0,5000	50,00
Superior	6	0,1667	16,67
Total	36	1,0000	100,00

- Número de realizações ou frequência: n_i
- Proporção: $f_i = \frac{n_i}{total}$
- Porcentagem: $100 * f_i$

Uma vantagem em utilizar a proporção para representar distribuições de frequência é comparar dados de tamanhos diferentes.

Tabela 2.2: Frequências e porcentagens dos 36 empregados da seção de orçamentos da Companhia MB segundo o grau de instrução.			
Grau de instrução	Freq ni	Proporção fi	Porcentagem 100 fi
Fundamental	12	0,3333	33,33
Médio	18	0,5000	50,00
Superior	6	0,1667	16,67
Total	36	1,0000	100,00
<i>Fonte: Tabela 2.1.</i>			

Tabela 2.3: Frequências e porcentagens dos 2.000 empregados da Companhia MB, segundo o grau de instrução.		
Grau de instrução	Freq ni	Porcentagem 100 fi
Fundamental	650	32,50
Médio	1.020	51,00
Superior	330	16,50
Total	2.000	100,00
<i>Fonte: Dados hipotéticos.</i>		

Exemplo com variáveis contínuas.

Quando queremos avaliar a frequência de uma variável contínua, precisamos dividir as realizações em classes e contar o número de realizações em cada classe.

Tabela 2.4: Frequências e porcentagens dos 36 empregados da seção de orçamentos da Companhia MB por faixa de salário.

Classe de salários	Frequência n_i	Porcentagem $\frac{100 f_i}{n}$
4,00 – 8,00	10	27,78
8,00 – 12,00	12	33,33
12,00 – 16,00	8	22,22
16,00 – 20,00	5	13,89
20,00 – 24,00	1	2,78
Total	36	100,00

Gráficos


Usamos representações gráficas para melhorar a visualização da distribuição (ou comportamento) de uma variável.

A vantagem desse tipo de representação é a possibilidade de uma interpretação mais rápida dos dados.

A seguir veremos alguns exemplos de gráficos.


Tipos de gráficos

- Barras.



- Setores (ou pizza).


Figura 2.3: Gráfico em setores para a variável *Y*: grau de instrução.



1 = Fundamental, 2 = Médio e 3 = Superior

- Dispersão unidimensional

Figura 2.5: Gráficos de dispersão unidimensionais para a variável Z : número de filhos.




- Histograma

O histograma é um gráfico de barras tal que a largura representa um intervalo de classe e a área é proporcional à frequência (**dados quantitativos contínuos**).

Diferença: no gráfico de barras comum, as barras têm largura igual e representam categorias (dados qualitativos);


Gráfico de Barras vs. Histograma

Gráfico de Barras



Dados qualitativos (categorias). Barras com largura igual e separadas por espaços.

Histograma




Dados quantitativos contínuos (intervalos de classe). Altura = densidade de frequência (f_i/n dividido pela amplitude); área total dos retângulos = 1.

Cálculos para se fazer o histograma:


- as bases são proporcionais aos intervalos das classes
- a área de cada retângulo é proporcional à respectiva frequência.
- Se a base do intervalo i é denotada por Δ_i , então a altura do retângulo correspondente é proporcional a $\frac{f_i}{\Delta_i}$.
- A soma das áreas dos retângulos será igual a 1.

Tente fazer os cálculos e chegar no seguinte histograma (casa)




Também podemos usar o histograma para variáveis discretas. Basta adaptar as realizações como intervalos de tamanho iguais

Figura 2.8: Histograma da variável Z : número de filhos.



Histograma com Classes de Amplitudes Diferentes



Altura = densidade de frequência ($f_i/n \div \Delta i$), não frequência absoluta — larguras maiores podem ter alturas menores.

Tipos de gráficos

- Ramo-e-folhas

Um gráfico do tipo ramo-e-folhas é uma tabela com uma linha vertical separando a primeira coluna das demais. Cada ocorrência da variável é dividida em duas informações:

- O ramo (primeira coluna).
- As folhas (linhas). É o complemento da informação colocada a direita do ramo.

Ramo-e-folhas

Figura 2.9: Ramo-e-folhas para a variável S: salários.

4	00 56
5	25 73
6	26 66 86
7	39 44 59
8	12 46 74 95
9	13 35 77 80
10	53 76
11	06 59
12	00 79
13	23 60 85
14	69 71
15	99
16	22 61
17	26
18	75
19	40
20	
21	
22	
23	30

Exemplo. Faça um gráfico de Ramo-e-folhas dos dados abaixo

Exemplo 2.9. Os dados abaixo referem-se à dureza de 30 peças de alumínio (Hoaglin, Mosteller e Tukey, 1983, pág. 13).

53,0	70,2	84,3	69,5	77,8	87,5	53,4	82,5	67,3	54,1
70,5	71,4	95,4	51,1	74,4	55,7	63,5	85,8	53,5	64,3
82,7	78,5	55,7	69,1	72,3	59,5	55,3	73,0	52,4	50,7

O primeiro passo é organizar os dados em ordem crescente:

50,7 — 51,1 — 52,4 — 53,0 — 53,4 — 53,5 — 54,1 — 55,3 — 55,7 — 55,7 — 59,5
63,5 — 64,3 — 67,3 — 69,1 — 69,5
70,2 — 70,5 — 71,4 — 72,3 — 73,0 — 74,4 — 77,8 — 78,5
82,5 — 82,7 — 84,3 — 85,8 — 87,5
95,4

Agora é só formatar os dados:

Figura 2.10: Ramo-e-folhas para os dados de dureza de peças de alumínio.

5	0 1 2 3 3 3 4 5 5 5 9
6	3 4 7 9 9
7	0 0 1 2 3 4 7 8
8	2 2 4 5 7
9	5


Todos os gráficos apresentados podem ser usados para variáveis discretas ou contínuas. Em alguns casos, para variáveis contínuas é necessário discretizar os dados, ou seja, dividir os dados em classes. Veja o exemplo abaixo:

Tabela 2.6: Distribuição de frequências da variável S, salário dos empregados da seção de orçamentos da Companhia MB.

Classes de salários	Ponto médio si	Freqüência ni	Porcentagem 100 fi
4,00 ─ 8,00	6,00	10	27,78
8,00 ─ 12,00	10,00	12	33,33
12,00 ─ 16,00	14,00	8	22,22
16,00 ─ 20,00	18,00	5	13,89
20,00 ─ 24,00	22,00	1	2,78
Total	—	36	100,00

Fonte: Tabela 2.4.

Figura 2.6: Gráfico em barras para a variável S: salários.



Existem vários tipos de gráficos. A escolha do gráfico depende do tipo de dados e da informação que queremos enfatizar

91%

Texto simples



Gráfico de dispersão

	A	B	C
Categoria 1	15%	22%	42%
Categoria 2	40%	36%	20%
Categoria 3	35%	17%	34%
Categoria 4	30%	29%	26%
Categoria 5	55%	30%	58%
Categoria 6	11%	25%	49%

Mapa de calor




Mapa de inclinação

	A	B	C
Categoria 1	15%	22%	42%
Categoria 2	40%	36%	20%
Categoria 3	35%	17%	34%
Categoria 4	30%	29%	26%
Categoria 5	55%	30%	58%
Categoria 6	11%	25%	49%

Tabela




Linha



Barras verticais



Barras horizontais




Barras verticais empilhadas



Barras horizontais empilhadas



Cascata



Área quadrada

Exercício (casa). Leia a seção 2.7 do livro (Bussab & Morettin) itens 3 e 4 ou pesquise sobre o tema “Frequências acumuladas”.

Medidas de posição

É um número que representa um conjunto de dados.

- **Moda:** é a realização mais frequente do conjunto de valores
- **Mediana:** é a realização que ocupa a posição central da série (ordenada) de observações.
- **Média (média aritmética):** é a soma das observações dividido pelo número delas.

Medidas de posição

Exemplo: Considere o conjunto de dados $\{4,0,5,1,7,2,3,3,5,1\}$.

- **Moda:**
- **Mediana:**
- **Média:**

Medidas de posição (fórmulas)

Sejam $\{x_1, x_2, \dots, x_k\}$ um conjunto de dados (distintos ou não).

- **Média:**

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_k}{k}$$

$$= \frac{n_1 x_1 + n_2 x_2 + \dots + n_j x_j}{k}, \quad j \leq k \text{ } (n_i = n^{\circ} \text{ de repetições})$$

$$= f_1 x_1 + f_2 x_2 + \dots + f_j x_j, \quad j \leq k \text{ } (f_i = \text{frequência})$$

- **Mediana:**

Considere o conjunto de dados $X = \{x_1, x_2, \dots, x_k\}$ e ordene os dados de forma crescente:

$$x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \dots \leq x_{(k)}$$

- Se k é par, $md(X) = \frac{x_{\left(\frac{k}{2}\right)} + x_{\left(\frac{k}{2}+1\right)}}{2}$
- Se k é ímpar, $md(X) = x_{\left(\frac{k+1}{2}\right)}$

Atividades referentes à aula

Leitura recomendada:

- Bussab & Morettin — Cap. 2: 2.1 a 2.4 (tabelas, gráficos, ramo-e-folhas) e Cap. 3: 3.1 (medidas de posição)
- Montgomery & Runger — Cap. 6: 6.1 a 6.3
- Magalhães & Lima — Cap. 1: 1.2

Exercícios recomendados:

- Bussab, Cap. 2: exercícios 1 ao 8 e 9 ao 20 (gráficos); exercícios 15, 16 e 17 (frequências acumuladas)
- Bussab, Cap. 3: exercícios de 1 a 13 (medidas de posição)