

CEA055 – Estatística e Probabilidade

Lista de Exercícios 2 – Estatística Descritiva II (medidas de dispersão, quantis empíricos e box plots)

Aviso: esta lista de exercícios foi elaborada com o auxílio da IA Claude (Anthropic). Os problemas são originais (não copiados de nenhum livro-texto). As fórmulas e convenções usadas foram conferidas contra a bibliografia da disciplina. Revise as respostas com atenção – como em qualquer material gerado com apoio de IA, pode haver imprecisões.

Parte 1 – Revisão de conceitos

1. Classifique cada afirmação como Verdadeira ou Falsa, **justificando** em uma frase:
 - (a) A variância é sempre expressa na mesma unidade de medida dos dados originais.
 - (b) O desvio padrão nunca é negativo.
 - (c) Um ponto marcado como "exterior" (fora dos limites) em um box plot é necessariamente um erro de medição.
2. O que significa dizer que uma medida de dispersão é *resistente* (ou robusta)? Cite um exemplo de medida resistente e um de medida não resistente, entre as que vimos em aula.
3. Dois conjuntos de dados têm a mesma média, mas desvios padrão diferentes. O que isso indica sobre a diferença entre os dois conjuntos?

Parte 2 – Resolução (fórmulas e cálculos)

4. O peso (em kg) de 5 pacotes enviados por uma transportadora foi: 2, 4, 4, 4, 6. Calcule a variância e o desvio padrão desse conjunto.
5. A idade de 9 participantes de uma pesquisa foi: 22, 25, 19, 30, 28, 24, 26, 21, 35.
 - (a) Ordene os dados e calcule a mediana.
 - (b) Calcule q_1 e q_3 (mediana da primeira e da segunda metade dos dados, sem incluir a mediana geral).
 - (c) Calcule a distância interquartil $dq = q_3 - q_1$.
6. O tempo de espera (em minutos) de 8 clientes em uma fila foi: 5, 8, 3, 10, 12, 6, 9, 7. Calcule q_1 , q_2 (mediana) e q_3 , usando o mesmo método do exercício anterior.
7. O número de clientes atendidos por dia em uma loja, ao longo de 11 dias, foi:
$$45, 50, 48, 52, 47, 49, 51, 46, 53, 48, 95$$
 - (a) Ordene os dados e obtenha o esquema dos cinco números: $x_{(1)}$, q_1 , q_2 (mediana), q_3 , $x_{(n)}$.
 - (b) Calcule os limites $LI = q_1 - 1,5 dq$ e $LS = q_3 + 1,5 dq$.
 - (c) Existe algum valor fora do intervalo $[LI, LS]$? Se sim, qual?

8. Dois grupos de 5 funcionários têm o mesmo salário médio (R\$ 10 mil), mas as distribuições são diferentes:

Grupo A: 10, 10, 10, 10, 10 Grupo B: 5, 8, 10, 12, 15 (em R\$ mil)

Calcule a variância de cada grupo e diga qual grupo é mais homogêneo.

Parte 3 – Desafio

Desafio

9. Retome os dados do Exercício 7 (número de clientes atendidos por dia, com o valor 95 identificado como ponto exterior).
- (a) Calcule a média e o desvio padrão **com** o valor 95 incluído.
 - (b) Remova o valor 95 e recalcule a média, a mediana e o desvio padrão **sem** ele.
 - (c) Compare: qual medida de posição (média ou mediana) mudou proporcionalmente mais ao remover o valor discrepante? E qual medida de dispersão (desvio padrão ou dq , calculado no Exercício 7) foi mais afetada?
 - (d) Com base na comparação acima, explique com suas palavras por que dizemos que a mediana e a distância interquartil são medidas *resistentes*, enquanto a média e o desvio padrão não são.

Parte 4 – Desafio bônus (opcional, não vale nota)

Bônus – Python no Google Colab

10. Exercício opcional, para quem quiser praticar programação. Não precisa instalar nada – roda direto no [Google Colab](#).

- (a) Carregue o conjunto de dados `wine` (composição química de vinhos de três cultivares diferentes), já disponível no `scikit-learn`:

```
from sklearn.datasets import load_wine
import pandas as pd

dados = load_wine(as_frame=True)
df = dados.frame
df.head()
```

- (b) Calcule a variância e o desvio padrão da coluna `alcohol` (teor alcoólico). **Atenção:** por padrão, o Python calcula variância e desvio padrão usando o denominador $n - 1$ (temos motivos para isso, mas isso é assunto de uma aula futura). Para obter o mesmo resultado que aprendemos em aula (denominador n), use o argumento `ddof=0`:

```
df["alcohol"].var(ddof=0)
df["alcohol"].std(ddof=0)
```

- (c) Construa um box plot da coluna `alcohol`:

```
df.boxplot(column="alcohol")
```

- (d) O método `.quantile()` do Python usa, por padrão, um jeito de calcular quartis **ligeiramente diferente** do que fizemos à mão em aula (o resultado costuma ficar bem próximo, mas não é sempre idêntico). Calcule q_1 e q_3 com:

```
df["alcohol"].quantile(0.25)
df["alcohol"].quantile(0.75)
```

- (e) O box plot mostra algum ponto exterior? Em uma frase, comente o que isso indica sobre o teor alcoólico dos vinhos da amostra.