CEA055 – Estatística e Probabilidade

População, Amostra e Parâmetros

Objetivos da aula:

- Compreender os conceitos de população e amostra.
- Conhecer os tipos de amostragem, com foco na Amostragem Aleatória Simples (AAS).
- Diferenciar estatística (medida da amostra) de parâmetro (medida da população).

Referências:

- Bussab, Morettin. **Estatística Básica**, 9ed — Cap. 10 (10.2, 10.4, 10.5, 10.6, 10.14)
- Montgomery, Runger. **Estatística Aplicada e Probabilidade para Engenheiros**, 7ª ed — Cap. 7 (7.1)
- Magalhães, Lima. **Noções de Probabilidade e Estatística**, 5ed — Cap. 1 (1.1); Cap. 7 (7.1)
- Morettin. **Estatística Básica: Probabilidade e Inferência** — Cap. 7 (7.1, 7.2)

Professor: Marcos Goulart Lima

Introdução

- Na Parte 1 - Resumo dos dados.
- Na Parte 2 - Modelos teóricos (probabilísticos).

Agora começamos a apresentar os argumentos estatísticos para fazer afirmações sobre as características de uma população, com base em informações dadas por amostras.

Conceitos básicos

População é o conjunto formado por indivíduos ou objetos que têm pelo menos uma variável comum e observável.

Amostra: fixada uma população, qualquer subconjunto formado exclusivamente por seus elementos é denominado amostra desta população.

Amostragem: é o processo de seleção de uma amostra, que possibilita o estudo das características da população.

Parâmetro, estimador e estimativa

- **Parâmetro** (θ)**:** medida que descreve uma característica numérica da população.

  Em geral é desconhecido: é o que queremos descobrir.

- **Estimador** $(\hat{\theta})$**:** também chamado de estatística; é uma função dos elementos da amostra, uma regra de cálculo que vale para qualquer amostra.

- **Estimativa** $(\hat{\theta}_0)$**:** o valor numérico que o estimador assume na amostra que foi de fato observada.

Notação

Os parâmetros usam letras gregas; os estimadores, letras latinas ou o "chapéu".

Medida	Parâmetro (população)	Estimador (amostra)
Média	μ	$\bar{X}$
Variância	σ^2	S^2
Proporção	p	$\hat{p}$

Exemplo. Um aplicativo de entregas quer conhecer o tempo médio de entrega dos 12.000 pedidos feitos no mês. A equipe sorteia 5 pedidos e anota os tempos, em minutos: 30, 25, 40, 35 e 20.

- **Parâmetro:** o tempo médio (μ) de todos os 12.000 pedidos. É desconhecido.
- **Estimador:** a média amostral, uma regra que vale para qualquer amostra de 5 pedidos.

$$\bar{X} = \frac{X_1 + X_2 + X_3 + X_4 + X_5}{5}$$

- **Estimativa**: o valor do estimador nesta amostra.

$$\bar{x}_1 = \frac{30+25+40+35+20}{5} = \frac{150}{5} = 30 \text{ minutos}$$

Se outra amostra trouxesse 22, 38, 31, 27 e 37, a estimativa seria

$$\bar{x}_2 = \frac{22+38+31+27+37}{5} = \frac{155}{5} = 31 \text{ minutos}$$

O parâmetro é o mesmo, mas cada amostra dá uma estimativa diferente.

Erro amostral

É o erro que ocorre justamente pelo uso da amostra. Ele é definido por

$$\epsilon = \hat{\theta} - \theta$$

Cada amostra sorteada dá uma estimativa diferente; por isso o erro amostral muda de amostra para amostra.

Na prática não conseguimos calculá-lo, porque θ é desconhecido. Nas próximas aulas veremos como medir o seu tamanho típico.

Tipos de amostragem

Queremos uma amostra **representativa** (a população em pequena escala); o melhor modo de garantir isso é o sorteio.

- **Probabilística:** cada elemento da população tem probabilidade **conhecida e não nula** de entrar na amostra. Ex.: aleatória simples, estratificada, por conglomerados, sistemática.
- **Não probabilística:** a probabilidade de seleção é **desconhecida**. Ex.: voluntários, conveniência (os mais fáceis de alcançar), intencional (escolhidos por um especialista).

Só a amostra probabilística permite medir a precisão da estimativa com a própria amostra.

Viés (ou vício)

Viés é um erro **sistemático**: puxa o resultado sempre para o mesmo lado. Pode aparecer em três lugares:

- **Viés de seleção:** o modo de escolher a amostra favorece uma parte da população (por exemplo, só quem quis responder). O sorteio evita esse viés.
- **Viés de coleta de dados:** o modo de medir ou de perguntar distorce a resposta (pergunta tendenciosa, instrumento mal calibrado, troca de quem não respondeu).
- **Viés de estimação:** o estimador erra sistematicamente para o mesmo lado (volta na Aula 16).

Exemplo. Uma rede de cinemas quer saber que nota o público dá ao novo filme de super-heróis.

- **Probabilística**: sorteia 400 compradores de ingresso cadastrados no aplicativo.
- **Voluntários**: usa as notas deixadas no site por quem quis avaliar (quem amou ou odiou o filme): viés de seleção.
- **Conveniência**: entrevista quem sai da sessão de estreia, à meia-noite (quase todos fãs): viés de seleção, puxando a nota para cima.
- **Intencional**: escolhe 10 críticos de cinema, que não representam o público.

Só a primeira permite medir a precisão da estimativa com a própria amostra.

Exemplo. Um estúdio lançou um jogo que já tem 400 mil jogadores. Para saber a proporção de jogadores que recomendam o jogo, o time de dados sorteia 1.000 jogadores e envia uma pergunta dentro do jogo. Dos 1.000, 780 responderam que recomendam.

Identifique a população, a amostra, a variável, o parâmetro, o estimador e a estimativa.

Resolução

- **População:** os 400 mil jogadores. **Amostra:** os 1.000 sorteados.
- **Variável:** $X = 1$ se o jogador recomenda e $X = 0$ se não recomenda.
- **Parâmetro:** p = proporção de *todos* os jogadores que recomendam. É desconhecido: é o que queremos descobrir.
- **Estimador:** a proporção amostral $\hat{p} = \frac{\text{número de sim na amostra}}{n}$ — uma regra que vale para qualquer amostra.
- **Estimativa:** o valor do estimador nesta amostra, $\hat{p} = \frac{780}{1000} = 0{,}78$.

Erro amostral: $\epsilon = \hat{p} - p$. Não dá para calcular, porque p é desconhecido. Se um levantamento completo mostrasse $p = 0{,}80$, o erro seria $0{,}78 - 0{,}80 = -0{,}02$.

Amostragem aleatória simples (AAS)

Todo elemento da população tem a mesma chance de ser sorteado.

- **Com reposição:** o elemento sorteado volta e pode sair de novo. Em cada retirada, cada elemento tem chance $1/N$.
- **Sem reposição:** cada elemento sai no máximo uma vez. A chance de um elemento específico estar na amostra é n/N.

Notação: $X_1, X_2, \ldots, X_n$ são os valores da 1ª, 2ª, …, n-ésima retirada. Com reposição, eles são independentes e cada um tem a mesma distribuição de X na população. É essa AAS que usaremos nas próximas aulas.

Exemplo. Considere a população formada pelos números de 1 a 9, com $N = 9$ elementos.

O **parâmetro** é a média populacional: $\mu = \frac{1+2+\cdots+9}{9} = \frac{45}{9} = 5$.

- Sorteamos amostras de tamanho $n = 3$ por AAS e usamos como estimador a média amostral. Em cada amostra, o erro amostral é $\epsilon = \bar{x} - \mu$.
- Na AAS, todas as amostras possíveis têm a mesma probabilidade. Com reposição, há $9 \cdot 9 \cdot 9 = 729$ amostras ordenadas, cada uma com probabilidade: $1/729$.
- Com reposição, um elemento pode sair mais de uma vez. As amostras com o maior erro são: $(1,1,1) \Rightarrow \bar{x} = 1 \Rightarrow \epsilon = 1 - 5 = -4$ e $(9,9,9) \Rightarrow \bar{x} = 9 \Rightarrow \epsilon = 9 - 5 = 4$

Logo, com reposição, o erro amostral fica entre −4 e 4: $|\epsilon| \leq 4$

- Sem reposição, cada elemento sai no máximo uma vez. $\text{Há } 9 \cdot 8 \cdot 7 = 504$ amostras ordenadas, cada uma com probabilidade: 1/504
- As amostras com o maior erro são:
  - $(1,2,3) \Rightarrow \bar{x} = 2 \Rightarrow \epsilon = 2 - 5 = -3$
  - $(7,8,9) \Rightarrow \bar{x} = 8 \Rightarrow \epsilon = 8 - 5 = 3$

Logo, sem reposição, o erro amostral fica entre −3 e 3: $|\epsilon| \leq 3$.

Amostragem estratificada

Dividimos a população, por uma variável critério, em grupos que não se sobrepõem: os estratos (campus, curso, tipo de cliente…).

Os estratos devem ser homogêneos por dentro e diferentes entre si.

Em cada estrato sorteamos uma AAS; a amostra final reúne todas.

O tamanho da amostra em cada estrato pode ser igual para todos ou proporcional ao tamanho do estrato: $n_h = n \cdot \frac{N_h}{N}$

Exemplo. Voltamos à população dos números de 1 a 9, com $\mu = 5$. Usamos o próprio valor como variável critério e separamos a população em três estratos de 3 elementos:

$$E_1 = \{1,2,3\}, \qquad E_2 = \{4,5,6\}, \qquad E_3 = \{7,8,9\}$$

As médias dos estratos são:

$$\mu_1 = \frac{1+2+3}{3} = 2, \qquad \mu_2 = \frac{4+5+6}{3} = 5, \qquad \mu_3 = \frac{7+8+9}{3} = 8.$$

Observe que dentro de cada estrato os valores são parecidos, e de um estrato para outro são muito diferentes. É a situação ideal para estratificar.

Sorteamos uma amostra de tamanho $n = 3$ com um elemento de cada estrato (alocação igual).

Há $3 \cdot 3 \cdot 3 = 27$ amostras possíveis, cada uma com probabilidade: $1/27$.

As amostras com o maior erro pegam o menor ou o maior valor de cada estrato:

- $(1,4,7) \Rightarrow \bar{x} = \frac{1+4+7}{3} = 4 \Rightarrow \epsilon = 4 - 5 = -1$
- $(3,6,9) \Rightarrow \bar{x} = \frac{3+6+9}{3} = 6 \Rightarrow \epsilon = 6 - 5 = 1$

Logo, na amostra estratificada, o erro amostral fica entre -1 e 1: $|\epsilon| \leq 1$.

Amostragem por conglomerados

A população é dividida em grupos (conglomerados): bairros, quadras, turmas, servidores…

Sorteamos alguns conglomerados e observamos **todos** os elementos deles. A unidade de sorteio passa a ser o grupo, não o elemento.

Funciona melhor quando cada conglomerado é heterogêneo por dentro (uma "miniatura" da população) e os conglomerados são parecidos entre si — o contrário dos estratos.

Exemplo. Uma fábrica produz 50.000 parafusos por dia, embalados em 500 caixas de 100. O controle de qualidade quer estimar a proporção de parafusos defeituosos. Para uma AAS, seria preciso numerar os 50.000 parafusos, abrir todas as caixas e procurar cada sorteado. Isso é caro e demorado.

Por conglomerados: cada caixa é um conglomerado. Sorteamos 10 caixas e inspecionamos todos os 100 parafusos de cada uma, 1.000 no total.

A unidade de sorteio passa a ser a caixa, não o parafuso. Só precisamos da lista de caixas, que já existe no estoque.

Funciona bem se cada caixa mistura parafusos de várias máquinas e turnos, como uma "miniatura" da produção.

Se cada caixa vier de uma só máquina, o sorteio pode cair só em caixas da máquina com defeito, e a estimativa erra muito.

Vantagem: coleta mais barata. Custo: em geral, exige amostra maior que a AAS para a mesma precisão.

Amostragem sistemática

Consideramos uma população de tamanho N e dela tiramos uma amostra de tamanho n. Definimos o fator de sistematização

$$s = \frac{N}{n}.$$

Com a população ordenada, sorteamos um número r entre 1 e s e selecionamos os elementos da forma

$$r + ks, \qquad 0 \leq k \leq n - 1.$$

Exemplo. Uma linha produz 1.000 peças por turno, numeradas na ordem de fabricação. O controle de qualidade quer inspecionar 100 peças.

Fator de sistematização: $s = \frac{N}{n} = \frac{1000}{100} = 10$

Sorteamos o ponto de partida entre 1 e 10; digamos $r = 4$. Inspecionamos as peças $4, 14, 24, \ldots, 994$: uma a cada 10.

Vantagem: um único sorteio, e o operador só precisa contar as peças.

Resumo dos planos de amostragem

Plano	O que se sorteia	Quando é útil
Aleatória simples	os elementos, um a um, todos com a mesma chance	há uma lista da população; é o caso básico
Sistemática	só o primeiro (r); depois, de s em s	lista ordenada; prático. Cuidado com padrões que se repetem
Estratificada	uma AAS dentro de cada estrato	grupos diferentes entre si e homogêneos por dentro
Conglomerados	grupos inteiros	não há lista dos elementos, mas há lista dos grupos; coleta mais barata

Exemplo. Um servidor registrou 10.000 requisições em um dia: 6.000 vieram do site, 3.000 do aplicativo e 1.000 de integrações com outros sistemas (API). A equipe quer auditar 200 requisições.

Como sortear essa amostra em cada plano: amostragem aleatória simples, sistemática, estratificada e por conglomerados?

Resolução

- **AAS:** numerar as requisições de 1 a 10.000 e sortear 200 números diferentes (sem reposição).
- **Sistemática:** $s = \frac{10000}{200} = 50$; sortear r entre 1 e 50 (por exemplo, 13) e pegar 13, 63, 113, …, 9.963.
- **Estratificada (proporcional):** o site tem 60% das requisições, então $0{,}60 \cdot 200 = 120$; o aplicativo, $0{,}30 \cdot 200 = 60$; a API, $0{,}10 \cdot 200 = 20$. Dentro de cada estrato, sorteio aleatório.
- **Conglomerados:** dividir o dia em 144 blocos de 10 minutos (cerca de 70 requisições em cada) e sortear 3 blocos inteiros, auditando todas as requisições deles (cerca de 200).

Atividades referentes à aula

Leitura recomendada:

- Bussab & Morettin — Cap. 10: 10.2, 10.4, 10.5, 10.6 e 10.14 (item 2, Planos probabilísticos)
- Montgomery & Runger — Cap. 7: 7.1
- Magalhães & Lima — Cap. 1: 1.1 (trecho sobre seleção da amostra); Cap. 7: 7.1
- Morettin — Cap. 7: 7.1, 7.2

Atividades referentes à aula (continuação)

Exercícios recomendados:

- Bussab & Morettin — Cap. 10: Problemas 1 e 31
- Magalhães & Lima — Cap. 7: Exercícios da Seção 7.1, 1 e 2