CEA055 – Estatística e Probabilidade

Distribuição Amostral da Média e da Proporção

Objetivos da aula:

- Obter a distribuição amostral da média e calcular probabilidades com ela.
- Entender o Teorema do Limite Central (TLC).
- Aproximar a distribuição binomial pela normal.
- Obter a distribuição amostral da proporção.

Referências:

- Bussab, Morettin. **Estatística Básica**, 9ª ed. — Cap. 7 (7.5); Cap. 10 (10.7 a 10.9)
- Montgomery, Runger. **Estatística Aplicada e Probabilidade para Engenheiros**, 7ª ed. — Cap. 4 (4.6); Cap. 7 (7.2)
- Magalhães, Lima. **Noções de Probabilidade e Estatística**, 5ª ed. — Cap. 6 (6.2); Cap. 7 (7.3)
- Morettin. **Estatística Básica: Probabilidade e Inferência** — Cap. 6 (6.2); Cap. 9 (9.1, 9.2)

Professor: Marcos Goulart Lima

Cada amostra, uma estimativa

Na Aula 14, o app de entregas sorteou amostras de 5 pedidos:

Amostra	Tempos de entrega (min)	$\bar{x}$
1	30, 25, 40, 35, 20	30
2	22, 38, 31, 27, 37	31
3	?	?

- Cada amostra dá uma estimativa diferente.
- As amostras são sorteadas por AAS, ou seja, o valor de $\overline{X}$ é **aleatório**.
- A partir de cada amostra, temos uma estimativa. Assim, definimos variável aleatória $\overline{X}$ e, como visto anteriormente, podemos calcular a distribuição de probabilidade de $\overline{X}$.

Definição. A **distribuição amostral** de uma estatística é a distribuição de probabilidade dos valores que ela assume em todas as amostras possíveis de tamanho n, retiradas segundo o mesmo plano amostral.

Nesta aula veremos duas distribuições: a distribuição amostral da média $\overline{X}$ e da proporção $\hat{p}$.

Exemplo. Em um app, cada cliente avalia a entrega com uma nota de 1 a 5 estrelas, e cada nota aparece na mesma proporção. A população é {1, 2, 3, 4, 5}, com $\mu = 3$ e $\sigma^2 = 2$. Sorteamos 2 avaliações com reposição, ou seja, a mesma nota pode sair duas vezes. São $5 \times 5 = 25$ amostras possíveis, todas com a mesma chance. A tabela mostra a média $\bar{x}$ de cada uma:

1ª nota \ 2ª nota	1	2	3	4	5
1	1,0	1,5	2,0	2,5	3,0
2	1,5	2,0	2,5	3,0	3,5
3	2,0	2,5	3,0	3,5	4,0
4	2,5	3,0	3,5	4,0	4,5
5	3,0	3,5	4,0	4,5	5,0

A distribuição de $\overline{X}$

$\bar{x}$	1,0	1,5	2,0	2,5	3,0	3,5	4,0	4,5	5,0
$\boldsymbol{P}(\bar{\boldsymbol{X}} = \bar{\boldsymbol{x}})$	1/25	2/25	3/25	4/25	5/25	4/25	3/25	2/25	1/25

$$E(\overline{X}) = \sum \overline{x} P(\overline{X} = \overline{x}) = \frac{75}{25} = 3$$

$$E\left(\overline{X}^2\right) = \frac{250}{25} = 10 \;\Rightarrow\; \mathrm{Var}(\overline{X}) = 10 - 3^2 = 1$$

Compare com a população: a média é a mesma (3), e a variância caiu à metade (de 2 para 1).

Média e variância de $\overline{X}$

O resultado do exemplo não é coincidência: vale para qualquer população.

Proposição. Seja $X_1, \ldots, X_n$ uma amostra aleatória simples (com reposição, ou de uma população grande) de uma população com média μ e variância σ^2. Então:

$$E(\overline{X}) = \mu \qquad \text{e} \qquad \text{Var}(\overline{X}) = \frac{\sigma^2}{n}$$

- No exemplo: $E(\overline{X}) = 3$ e $\text{Var}(\overline{X}) = 2/2 = 1$.
- **Se a população tem distribuição normal**, $\overline{X}$ também tem, exatamente, para qualquer n: $\overline{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$.
- E quando a população **não** é normal?

Exemplo: o tempo de resposta da API

O tempo de resposta de um servidor de app (a API) segue uma exponencial com $\lambda = 1/200$ por ms (Aula 12). Logo, $\mu = 1/\lambda = 200$ ms e $\sigma = 1/\lambda = 200$ ms.

- A distribuição é bem **assimétrica**: a maioria das respostas é rápida, e algumas demoram muito.
- O painel de monitoramento mostra a **média de n respostas**.
- O alarme dispara se essa média passar de **250 ms**.

Pergunta do time: com o servidor funcionando normalmente, qual é a chance de um **alarme falso**?

Usamos o computador para sortear 100.000 amostras de tamanho n de tempos de resposta. Em seguida, calculamos a média de cada amostra e verificamos em que fração delas a média passou de 250 ms. Com isso, obtemos a tabela abaixo:

n	$DP(\bar{X}) = \frac{\sigma}{\sqrt{n}}$	$P(\bar{X} > 250)$: simulação	$P(\bar{X} > 250)$: pela normal
1	200,0 ms	0,285	0,401
2	141,4 ms	0,285	0,362
5	89,4 ms	0,252	0,288
10	63,2 ms	0,201	0,215
30	36,5 ms	0,093	0,085
100	20,0 ms	0,010	0,006

O que muda quando n cresce

- Com $n = 1$, a normal erra muito: a população é assimétrica.
- Com $n = 30$, a normal já fica próxima do que a simulação mostra.
- Em n = 100, as duas colunas ficam perto de zero (0,010 e 0,006). A diferença absoluta é pequena

A tabela indica que, com n grande, a normal descreve bem $\overline{X}$. Como veremos a seguir, isso vale em geral.

Teorema do Limite Central (TLC)

Seja $X_1, X_2, \ldots, X_n$ uma amostra aleatória simples de uma população com média μ e variância σ^2 finita. Então, para n grande, a distribuição amostral da média $\overline{X}$ é aproximadamente normal:

$$\overline{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{ou} \quad Z = \frac{\overline{X}-\mu}{\sigma/\sqrt{n}} \approx N(0,1)$$

- Vale **qualquer que seja o formato da população**.
- Quanto mais a população se afasta da normal, maior o n necessário. Regra prática: n ≥ 30.

Exemplo. Vamos calcular a chance de alarme falso do slide 7 usando o TLC.

Com $n = 30$, pelo TLC:

$$\overline{X} \approx N(200;\ 36,5^2),\ \text{pois}\ \frac{\sigma}{\sqrt{n}} = \frac{200}{\sqrt{30}} \approx 36{,}5\ \text{ms}$$

$$P(\overline{X} > 250) = P(Z > \frac{250 - 200}{36{,}5}) = P(Z > 1{,}37)$$

$$= 0{,}5 - P(0 \leq Z \leq 1{,}37) = 0{,}5 - 0{,}4147 = 0{,}0853$$

Em cerca de 8,5% das atualizações, o painel dispara alarme sem nenhum problema no servidor.

Aproximação normal à binomial

Até aqui, a estatística era uma média. Agora vamos olhar para uma contagem: o número de sucessos em n tentativas independentes, cada uma com probabilidade p de sucesso.

- Pela Aula 10: $Y \sim b(n, p)$, com $E(Y) = np$ e $\mathrm{Var}(Y) = np(1-p)$

Quando n é grande, calcular uma probabilidade como $P(Y \geq k)$ exige somar muitos termos da binomial. Para valores grandes de n, a distribuição de Y fica parecida com uma normal. Por isso, usamos uma normal com a mesma média e a mesma variância da binomial: $Y \approx N(np, np(1-p))$

Condição prática: $np \geq 5$ e $n(1-p) \geq 5$.

Correção de continuidade

Ao trocar a binomial pela normal, aparece um problema: a binomial só assume valores inteiros (0, 1, 2, …), mas a normal é contínua. Na normal, a probabilidade de um valor exato é zero: $P(Y = k) = 0$ pela normal, mas $P(Y = k) > 0$ pela binomial

A solução é pensar no histograma da binomial: cada valor k é uma barra de largura 1, que vai de $k - 0{,}5$ a $k + 0{,}5$. Na normal, usamos a área sobre esse intervalo. Esse ajuste de meia unidade é a correção de continuidade:

Probabilidade binomial	Use na normal
$P(Y = k)$	$P(k - 0{,}5 < Y < k + 0{,}5)$
$P(Y \leq k)$	$P(Y < k + 0{,}5)$
$P(Y \geq k)$	$P(Y > k - 0{,}5)$

Exemplo: pedidos atrasados

10% dos pedidos do app chegam atrasados. O time sorteia **400 pedidos**. Seja Y o número de atrasados: $Y \sim b(400;\ 0{,}10)$.

Qual a chance de **50 ou mais** atrasados? São 351 termos:

$$P(Y \geq 50) = P(Y = 50) + P(Y = 51) + \cdots + P(Y = 400)$$

Pela aproximação: $\mu = np = 40$ e $\sigma^2 = np(1-p) = 36$.

Condição: $np = 40 \geq 5$ e $n(1-p) = 360 \geq 5$.

Resolução: 50 ou mais atrasados

Com correção de continuidade ($\sigma = \sqrt{36} = 6$):

$$P(Y \geq 50) \approx P\left(Z > \frac{49{,}5 - 40}{6}\right) = P(Z > 1{,}58) = 0{,}5 - 0{,}4429 = 0{,}0571$$

Método	P(Y ≥ 50)
Binomial exata (computador)	0,0601
Normal com correção	0,0571
Normal sem correção	0,0475

A correção de continuidade aproxima o resultado do valor exato.

Distribuição amostral da proporção

Muitas vezes interessa a proporção, e não a contagem. Por exemplo, a proporção de pedidos atrasados numa amostra. Vamos estudar como se comporta a distribuição amostral da proporção.

Considere uma população em que uma fração p dos elementos tem certa característica. Para cada elemento sorteado, defina

- $X = 1$ se ele tem a característica e
- X=0 se não tem

Assim, X é uma Bernoulli: $E(X) = p$ e $Var(X) = p(1 - p)$

Numa amostra de n elementos, o número de sucessos é a soma dos X:

$Y = X_1 + X_2 + \cdots + X_n$, com $Y \sim b(n, p)$

A proporção de sucessos na amostra é

$$\hat{p} = \frac{Y}{n} = \frac{X_1 + \cdots + X_n}{n} = \bar{X}$$

Ou seja, a proporção amostral é uma média amostral.

Como $\hat{p}$ é uma média amostral, valem os resultados que já vimos para $\bar{X}$, com $\mu = p$ e $\sigma^2 = p(1-p)$. Pelo TLC, para n grande:

$$\hat{p} \approx N\left(p, \frac{p(1-p)}{n}\right)$$

Usaremos essa aproximação para: $np \geq 5$ e $n(1-p) \geq 5$.

Também podemos obter um resultado usando a variável Y (que conta o número de sucessos). Se $\hat{p} \approx N\left(p, \frac{p(1-p)}{n}\right)$ podemos multiplicar por n e obter:

$$Y = n\hat{p} \approx N(np, np(1-p))$$

Que é a aproximação normal à binomial que usamos antes.

Agora sabemos por que ela funciona: é o TLC.

Exemplo. Qual a chance de 12,5% ou mais de atrasados na amostra de 400 pedidos?

Resolução: lembre que $Y \sim b(400;\ 0{,}10)$. Logo,

- $E(\hat{p}) = p = 0{,}10$
- $\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0{,}10 \cdot 0{,}90}{400}} = 0{,}015$
- Segue que, $\hat{p} \approx N(0{,}10;\ 0{,}015^2)$

$$P(\hat{p} \geq 0{,}125) = P(Z \geq \frac{0{,}125 - 0{,}10}{0{,}015}) = P(Z \geq 1{,}67)$$

$$= 0{,}5 - P(0 \leq Z \leq 1{,}67) = 0{,}5 - 0{,}4525 = 0{,}0475$$

É o mesmo evento de $Y \geq 50$ (a normal sem correção na tabela de $P(Y \geq 50)$).

Resumo

Estatística	Média	Variância	Distribuição	Quando vale
$\bar{X}$	μ	σ^2/n	normal exata, se a população é normal; ≈ normal, pelo TLC	n ≥ 30 (regra prática)
$Y \sim b(n,p)$	np	$np(1-p)$	≈ normal, com correção de continuidade	np ≥ 5 e n(1 − p) ≥ 5
$\hat{p} = \frac{Y}{n}$	p	$\frac{p(1-p)}{n}$	≈ normal	np ≥ 5 e n(1 − p) ≥ 5

Atividades referentes à aula

Leitura recomendada:

- Distribuição amostral: Bussab & Morettin 10.7 a 10.9; Montgomery & Runger 7.2; Magalhães & Lima 7.3; Morettin 9.1 e 9.2.
- Aproximação normal à binomial: Bussab & Morettin 7.5; Montgomery & Runger 4.6; Magalhães & Lima 6.2; Morettin 6.2.

Exercícios recomendados:

- Bussab & Morettin — Cap. 7: Problemas 22, 23 e 24; Cap. 10: Problemas 4, 5, 6, 7, 8, 9, 10, 11, 12 e 13
- Magalhães & Lima — Cap. 7 (7.5 Exercícios): 5, 6, 9, 10, 11, 12, 13 e 14; Cap. 6 (6.3 Exercícios): 31
- Montgomery & Runger — 4.6.1, 4.6.3, 4.6.4, 4.6.8 e 4.6.9; 7.2.3, 7.2.4, 7.2.5, 7.2.6 e 7.2.8
- Morettin — Cap. 6: 4, 5, 6, 7, 8 e 9; Cap. 9: 1, 2, 3, 4 e 5