CEA055 – Estatística e Probabilidade

Distribuições Qui-Quadrado e t de Student

Objetivos da aula:

- Conhecer a distribuição qui-quadrado e a distribuição t de Student.
- Saber por que elas aparecem quando σ é desconhecido e usamos S.
- Ler valores nas tabelas de cauda superior.

Referências:

- Bussab, Morettin. **Estatística Básica**, 9ª ed. — Cap. 7 (7.7.2, 7.7.3); Cap. 12 (12.9, 12.10)
- Montgomery, Runger. **Estatística Aplicada e Probabilidade para Engenheiros**, 7ª ed. — Cap. 8 (8.2.1, 8.3)
- Magalhães, Lima. **Noções de Probabilidade e Estatística**, 5ª ed. — Cap. 8 (8.3, 8.5)
- Morettin. **Estatística Básica: Probabilidade e Inferência** — Cap. 14 (14.1); Cap. 16 (16.1)

Professor: Marcos Goulart Lima

Onde paramos

- Se a população é **normal**:
  - $\overline{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$
  - $Z = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$ (Aula 15).
- Para estimar σ^2, usamos
  - $S^2 = \frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n-1}$, que é não viesado (Aula 16).
- Vamos ver o que acontece com Z quando σ é **desconhecido** e colocamos S no lugar.

Termos da aula

- **Graus de liberdade (ν):** número que define a curva da t ou da χ^2 (qui-quadrado); nesta aula, $\nu = n - 1$.
- **Cauda superior:** área à **direita** de um valor.
- $t_{\alpha;\nu}$: valor com área α à sua direita na t com ν graus de liberdade.
- $\chi^2_{\alpha;\nu}$: valor com área α à sua direita na qui-quadrado com ν graus de liberdade.

Exemplo 1 — O que acontece se trocarmos σ por S?

O tempo de resposta de uma API de pagamentos tem distribuição normal, com $\mu = 250$ms e $\sigma = 40$ms: $X \sim N(250, 40^2)$.

A equipe de informática sorteia amostras de $n = 10$ requisições e calcula a média $\bar{X}$ de cada uma.

Com σ conhecido, sabemos que $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$: em 95% das amostras, Z fica entre −1,96 e 1,96.

O problema é que a equipe não conhece σ. A ideia é usar o desvio padrão amostral S no lugar de σ.

Pergunta: com S no lugar de σ, ainda são 95% das amostras entre −1,96 e 1,96?

Como nós conhecemos $\sigma = 40$, podemos simular e medir o erro dessa ideia.

Simulação

Para cada tamanho n (5, 10 e 30), sorteamos **100 mil amostras** dessa API. Em cada uma, calculamos as duas padronizações:

$$\frac{\overline{X} - \mu}{S/\sqrt{n}}, \qquad \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

e contamos quantas ficaram **fora** de −1,96 a 1,96:

n	Com S	Com σ
5	12,1%	4,9%
10	8,1%	5,0%
30	5,8%	4,9%

Com S, **mais de 5%** ficam fora. A diferença diminui quando n cresce.

Por que S muda o resultado

- σ é um número fixo; S **muda de amostra para amostra**.
- Com $n = 10$, cerca de **56%** das amostras têm $S < \sigma$: o denominador fica menor e o quociente fica maior.
- Por isso, $\frac{\overline{X}-\mu}{S/\sqrt{n}}$ **varia mais** que Z e **não é normal**.

Como resolver o problema de não conhecer σ

Não conhecer σ nos obriga a usar S, e S muda de amostra para amostra. Para saber como a padronização com S se comporta, vamos em dois passos:

1. Como S^2 varia: com a qui-quadrado, descrevemos como S² muda entre as amostras.
2. Como a padronização com S varia: combinando a normal padrão com a qui-quadrado, chegamos à distribuição t de Student, que substitui a $N(0,1)$ quando usamos S no lugar de σ.

Começamos pela qui-quadrado.

Distribuição qui-quadrado

- **Definição.** Sejam $Z_1, \ldots, Z_\nu$ normais padrão **independentes**. A variável

$$Y = Z_1^2 + Z_2^2 + \cdots + Z_\nu^2$$

tem distribuição **qui-quadrado com ν graus de liberdade**:

$$Y \sim \chi^2(\nu)$$

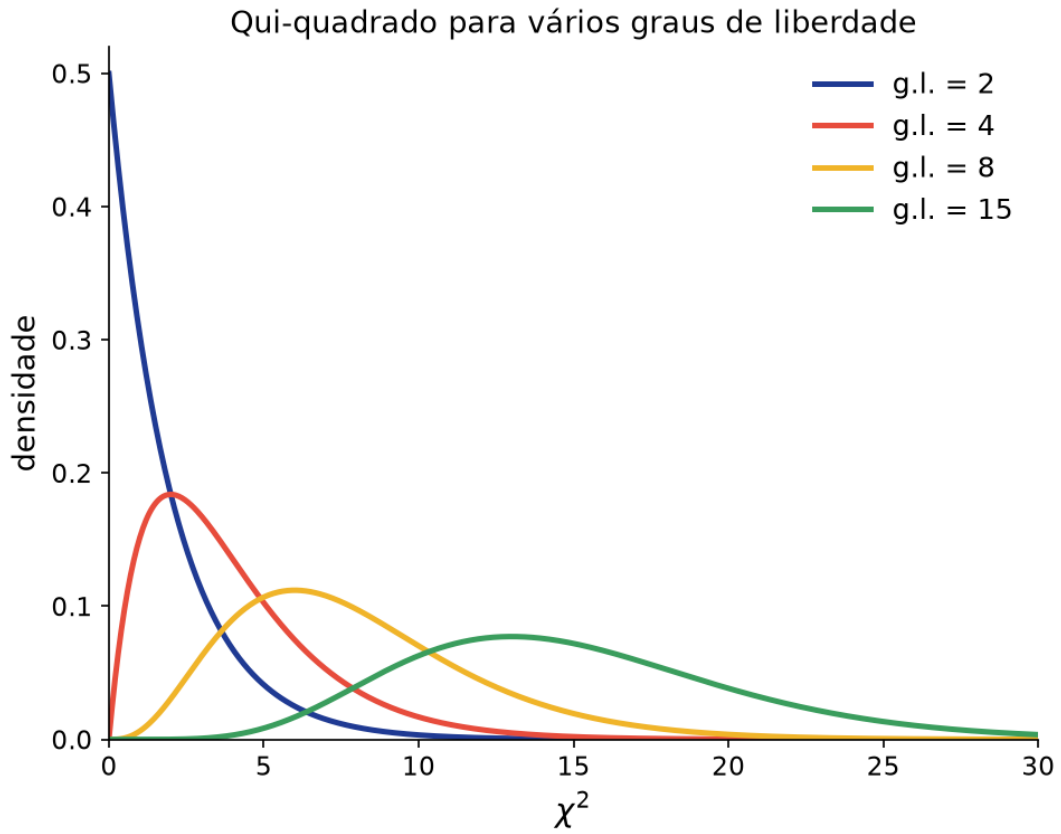
- **Média e variância da qui-quadrado**

$$E(Y) = \nu \qquad \mathrm{Var}(Y) = 2\nu$$

Como Y é soma de quadrados, ela só assume valores **maiores ou iguais a zero**.

O formato da qui-quadrado

Para ν pequeno, é **assimétrica à direita**. Quando ν cresce, fica mais simétrica e se aproxima de uma **normal**: com $\nu = 30$, já fica perto da $N(30{,}60)$.



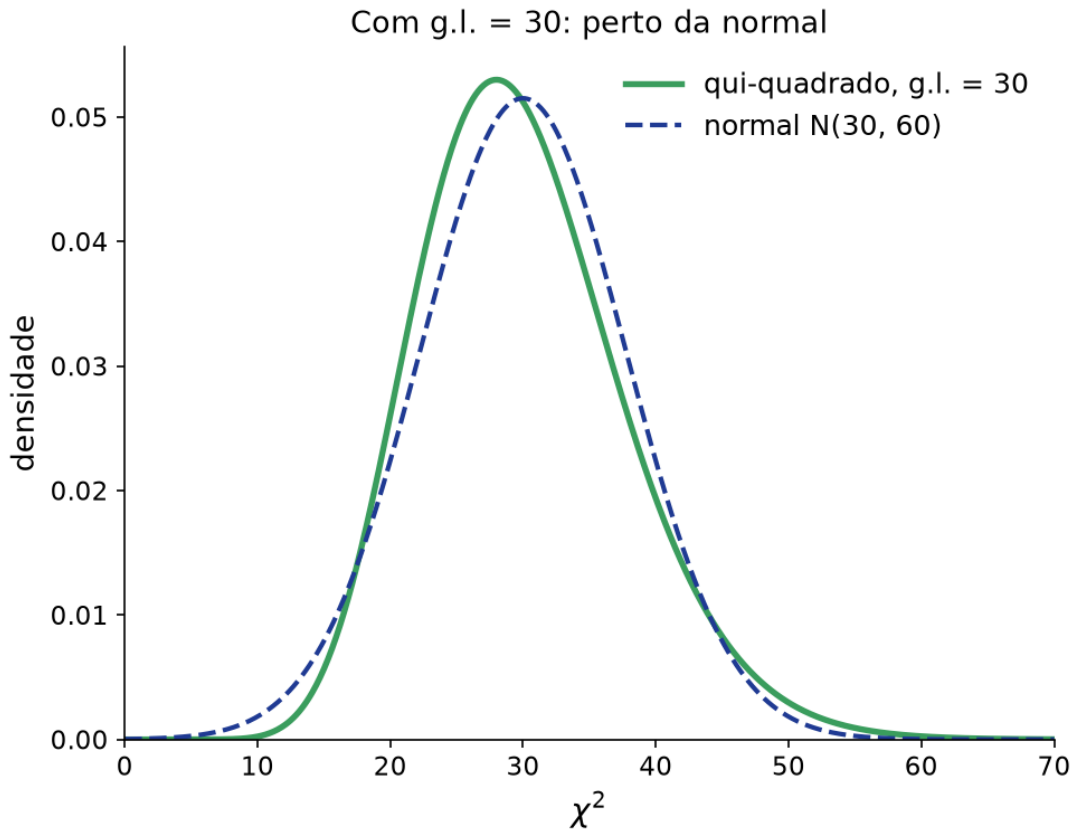


Tabela qui-quadrado (cauda superior) — parte 1 de 2

Corpo da tabela: $\chi^2_{\alpha;\nu}$ tal que $P(\chi^2 > \chi^2_{\alpha;\nu}) = \alpha$. Linha: ν; coluna: α.

ν	0,995	0,99	0,975	0,95	0,90	0,10	0,05	0,025	0,01	0,005
1	0,000	0,000	0,001	0,004	0,016	2,706	3,841	5,024	6,635	7,879
2	0,010	0,020	0,051	0,103	0,211	4,605	5,991	7,378	9,210	10,597
3	0,072	0,115	0,216	0,352	0,584	6,251	7,815	9,348	11,345	12,838
4	0,207	0,297	0,484	0,711	1,064	7,779	9,488	11,143	13,277	14,860
5	0,412	0,554	0,831	1,145	1,610	9,236	11,070	12,833	15,086	16,750
6	0,676	0,872	1,237	1,635	2,204	10,645	12,592	14,449	16,812	18,548
7	0,989	1,239	1,690	2,167	2,833	12,017	14,067	16,013	18,475	20,278
8	1,344	1,646	2,180	2,733	3,490	13,362	15,507	17,535	20,090	21,955
9	1,735	2,088	2,700	3,325	4,168	14,684	16,919	19,023	21,666	23,589
10	2,156	2,558	3,247	3,940	4,865	15,987	18,307	20,483	23,209	25,188
11	2,603	3,053	3,816	4,575	5,578	17,275	19,675	21,920	24,725	26,757
12	3,074	3,571	4,404	5,226	6,304	18,549	21,026	23,337	26,217	28,300
13	3,565	4,107	5,009	5,892	7,042	19,812	22,362	24,736	27,688	29,819
14	4,075	4,660	5,629	6,571	7,790	21,064	23,685	26,119	29,141	31,319
15	4,601	5,229	6,262	7,261	8,547	22,307	24,996	27,488	30,578	32,801
16	5,142	5,812	6,908	7,962	9,312	23,542	26,296	28,845	32,000	34,267
17	5,697	6,408	7,564	8,672	10,085	24,769	27,587	30,191	33,409	35,718
18	6,265	7,015	8,231	9,390	10,865	25,989	28,869	31,526	34,805	37,156

Tabela qui-quadrado (cauda superior) — parte 2 de 2

Corpo da tabela: $\chi^2_{\alpha;\nu}$ tal que $P(\chi^2 > \chi^2_{\alpha;\nu}) = \alpha$. Linha: ν; coluna: α.

ν	0,995	0,99	0,975	0,95	0,90	0,10	0,05	0,025	0,01	0,005
19	6,844	7,633	8,907	10,117	11,651	27,204	30,144	32,852	36,191	38,582
20	7,434	8,260	9,591	10,851	12,443	28,412	31,410	34,170	37,566	39,997
21	8,034	8,897	10,283	11,591	13,240	29,615	32,671	35,479	38,932	41,401
22	8,643	9,542	10,982	12,338	14,041	30,813	33,924	36,781	40,289	42,796
23	9,260	10,196	11,689	13,091	14,848	32,007	35,172	38,076	41,638	44,181
24	9,886	10,856	12,401	13,848	15,659	33,196	36,415	39,364	42,980	45,559
25	10,520	11,524	13,120	14,611	16,473	34,382	37,652	40,646	44,314	46,928
26	11,160	12,198	13,844	15,379	17,292	35,563	38,885	41,923	45,642	48,290
27	11,808	12,879	14,573	16,151	18,114	36,741	40,113	43,195	46,963	49,645
28	12,461	13,565	15,308	16,928	18,939	37,916	41,337	44,461	48,278	50,993
29	13,121	14,256	16,047	17,708	19,768	39,087	42,557	45,722	49,588	52,336
30	13,787	14,953	16,791	18,493	20,599	40,256	43,773	46,979	50,892	53,672
40	20,707	22,164	24,433	26,509	29,051	51,805	55,758	59,342	63,691	66,766
50	27,991	29,707	32,357	34,764	37,689	63,167	67,505	71,420	76,154	79,490
60	35,534	37,485	40,482	43,188	46,459	74,397	79,082	83,298	88,379	91,952
80	51,172	53,540	57,153	60,391	64,278	96,578	101,879	106,629	112,329	116,321
100	67,328	70,065	74,222	77,929	82,358	118,498	124,342	129,561	135,807	140,169

Exemplo 2 — Lendo a tabela qui-quadrado

Um sensor de temperatura de um data center faz 10 leituras independentes por minuto. O erro de cada leitura, já padronizado, tem distribuição normal padrão: $Z_1, \ldots, Z_{10} \sim N(0,1)$.

Para medir o ruído do sensor, a equipe calcula a soma dos quadrados dos erros:

$$Y = {Z_1}^2 + {Z_2}^2 + \cdots + {Z_{10}}^2$$

Pela definição, $Y \sim \chi^2(10)$.

Use a tabela qui-quadrado para responder:

(a) Que valor de Y só é ultrapassado em 5% dos minutos?

(b) Abaixo de que valor Y fica em apenas 5% dos minutos?

(c) Entre quais valores Y fica em 90% dos minutos, com 5% em cada ponta?

Resolução.

A tabela dá o valor de χ^2 que deixa a área α à sua direita. Para encontrá-lo, precisamos de ν (a linha) e de α (a coluna).

(a) Na linha $\nu = 10$ e coluna $\alpha = 0{,}05$, encontramos: $\boldsymbol{\chi^2}_{0,\,05;\,10} = \mathbf{18,307}$. Assim, $P(Y > 18{,}307) = 0{,}05$.

(b) Se só 5% ficam **abaixo**, então 95% ficam **acima**: área à direita = 0,95, então coluna 0,95: $\boldsymbol{\chi^2}_{0,\,95;\,10} = \mathbf{3,940}$. Assim, $P(Y < 3{,}940) = 0{,}05$.

(c) Juntando (a) e (b): $\boldsymbol{P(3,940 < Y < 18,307) = 0,90}$.

O seguinte resultado relaciona a variância populacional, a variância amostral e a distribuição χ^2

Se a amostra vem de uma população normal (Bussab, Corolário 12.1; Montgomery 8.3), então

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Por que $n-1$ graus de liberdade?

- S^2 usa $\overline{X}$ no lugar de μ: estimamos um parâmetro antes.
- Cada parâmetro estimado tira **1 grau de liberdade**: $\nu = n-1$ (Morettin 14.1).
- É o mesmo $n-1$ do denominador de S^2 (Aula 16).

Exemplo 3 — Variabilidade de parafusos

O diâmetro dos parafusos de uma máquina tem distribuição **normal**, com $\sigma = 0{,}04$ mm.

A cada turno, sorteiam-se $n = 20$ parafusos e calcula-se S^2.

Pergunta: abaixo de que **valor** ficam **95%** dos S^2 observados?

Resolução do Exemplo 3

Pelo enunciado temos: $\sigma^2 = 0,04^2 = 0{,}0016$ e $\nu = 20 - 1 = 19$.

Logo, $\frac{19S^2}{0{,}0016} \sim \chi^2(19)$.

A pergunta se refere a 95% abaixo de um valor, ou seja, a cauda da direita tem 5%.

Na tabela procuramos $\chi^2(19)$ com $\alpha = 5\%$: $\chi^2_{0{,}05;19} = 30{,}144$.

Agora voltamos à variável S^2 **:**

$$\frac{19S^2}{0{,}0016} \leq 30{,}144 \Rightarrow S^2 \leq \frac{30{,}144 \times 0{,}0016}{19} = 0{,}00254\ mm^2$$

Portanto, 95% dos valores de variância ficam abaixo de $0{,}00254\ mm^2$ ou

$$S \leq 0{,}0504\ mm$$

Distribuição t de Student

Definição. Sejam $Z \sim N(0,1)$ e $Y \sim \chi^2(\nu)$, **independentes**. A variável

$$T = \frac{Z}{\sqrt{Y/\nu}}$$

tem distribuição **t de Student com ν graus de liberdade**: $T \sim t(\nu)$ (Bussab, Teorema 7.1).

"Student" era o pseudônimo de W. S. Gosset.

Média e variância da t

$$E(T) = 0 \qquad \mathrm{Var}(T) = \frac{\nu}{\nu-2}, \text{ para } \nu > 2$$

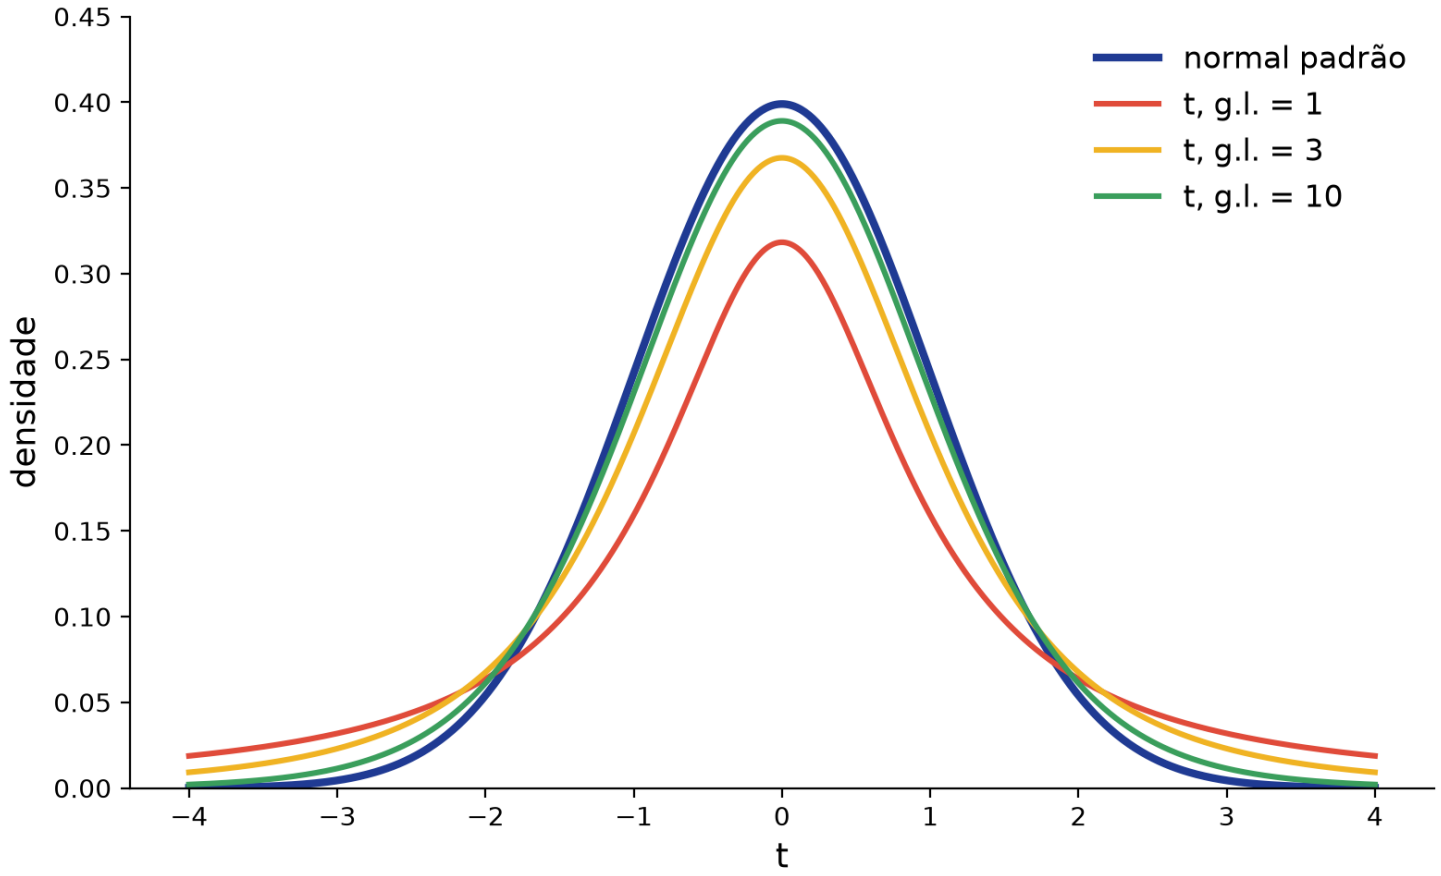
- A variância de T é sempre **maior que 1**. Comparando com a normal padrão que tem variância 1, podemos concluir que a t é mais espalhada que a normal padrão.

Observe que quando ν aumenta a variância se aproxima de 1:

- Para $\nu = 5, Var(T) = 5/3 \approx 1{,}67.$
- Para $\nu = 30, Var(T) = 30/28 \approx 1{,}07.$

A t e a normal padrão

Mesma forma de **sino**, simétrica em torno de zero, com **caudas mais pesadas**. Quando ν cresce, a t se aproxima da normal padrão.



A padronização com S

Se a amostra vem de uma população **normal**, então

$$T = \frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

(Bussab, eq. 12.9; Montgomery 8.2.1; Magalhães 8.3.)

Tabela t (cauda superior) — parte 1 de 2

Corpo da tabela: $t_{\alpha;\nu}$ tal que $P(T > t_{\alpha;\nu}) = \alpha$. À esquerda: $-t_{\alpha;\nu}$. Linha ∞: normal padrão.

ν	0,25	0,10	0,05	0,025	0,01	0,005	0,001
1	1,000	3,078	6,314	12,706	31,821	63,657	318,309
2	0,816	1,886	2,920	4,303	6,965	9,925	22,327
3	0,765	1,638	2,353	3,182	4,541	5,841	10,215
4	0,741	1,533	2,132	2,776	3,747	4,604	7,173
5	0,727	1,476	2,015	2,571	3,365	4,032	5,893
6	0,718	1,440	1,943	2,447	3,143	3,707	5,208
7	0,711	1,415	1,895	2,365	2,998	3,499	4,785
8	0,706	1,397	1,860	2,306	2,896	3,355	4,501
9	0,703	1,383	1,833	2,262	2,821	3,250	4,297
10	0,700	1,372	1,812	2,228	2,764	3,169	4,144
11	0,697	1,363	1,796	2,201	2,718	3,106	4,025
12	0,695	1,356	1,782	2,179	2,681	3,055	3,930
13	0,694	1,350	1,771	2,160	2,650	3,012	3,852
14	0,692	1,345	1,761	2,145	2,624	2,977	3,787
15	0,691	1,341	1,753	2,131	2,602	2,947	3,733
16	0,690	1,337	1,746	2,120	2,583	2,921	3,686
17	0,689	1,333	1,740	2,110	2,567	2,898	3,646

Tabela t (cauda superior) — parte 2 de 2

Corpo da tabela: $t_{\alpha;\nu}$ tal que $P(T > t_{\alpha;\nu}) = \alpha$. À esquerda: $-t_{\alpha;\nu}$. Linha ∞: normal padrão.

ν	0,25	0,10	0,05	0,025	0,01	0,005	0,001
18	0,688	1,330	1,734	2,101	2,552	2,878	3,610
19	0,688	1,328	1,729	2,093	2,539	2,861	3,579
20	0,687	1,325	1,725	2,086	2,528	2,845	3,552
21	0,686	1,323	1,721	2,080	2,518	2,831	3,527
22	0,686	1,321	1,717	2,074	2,508	2,819	3,505
23	0,685	1,319	1,714	2,069	2,500	2,807	3,485
24	0,685	1,318	1,711	2,064	2,492	2,797	3,467
25	0,684	1,316	1,708	2,060	2,485	2,787	3,450
26	0,684	1,315	1,706	2,056	2,479	2,779	3,435
27	0,684	1,314	1,703	2,052	2,473	2,771	3,421
28	0,683	1,313	1,701	2,048	2,467	2,763	3,408
29	0,683	1,311	1,699	2,045	2,462	2,756	3,396
30	0,683	1,310	1,697	2,042	2,457	2,750	3,385
40	0,681	1,303	1,684	2,021	2,423	2,704	3,307
60	0,679	1,296	1,671	2,000	2,390	2,660	3,232
120	0,677	1,289	1,658	1,980	2,358	2,617	3,160
∞	0,674	1,282	1,645	1,960	2,326	2,576	3,090

Exemplo 4 — Lendo a tabela t

Um time de ciência de dados mede o tempo de treinamento de um modelo em $n = 16$ execuções. O tempo tem distribuição normal e σ é desconhecido; por isso, a média é padronizada com S, e essa padronização segue $t(15)$.

Use a tabela t para responder:

(a) Que valor de T só é ultrapassado em 5% das amostras?

(b) Que valor de T só é ultrapassado em 2,5% das amostras?

(c) Como esses valores se comparam com os da normal padrão (1,645 e 1,960)?

Resolução do Exemplo 4

Pelo enunciado, $\nu = 16 - 1 = 15$: usamos a linha 15 da tabela t (Morettin 14.1).

(a) 5% à direita → coluna 0,05: $t_{0,05;15} = \mathbf{1,753}$.

(b) 2,5% à direita → coluna 0,025: $t_{0,025;15} = \mathbf{2,131}$.

(c) Na normal padrão, seriam 1,645 e 1,960. Os valores da t são maiores porque as caudas da t são mais pesadas: é preciso ir mais longe de zero para deixar a mesma área.

Exemplo 5 — O novo “1,96”

O tempo de resposta de uma API de pagamentos tem distribuição normal, mas a equipe de informática não conhece σ e padroniza a média com S.

Em cada amostra de $n = 10$ requisições, calcula-se $T = \frac{\overline{X} - \mu}{S/\sqrt{10}}$.

Pergunta: que valor c deixa **95%** dos valores de T entre $-c$ e c?

Resolução do Exemplo 5

Passo 1. $T \sim t(9)$, porque $\nu = 10 - 1 = 9$.

Passo 2. 95% no meio ⇒ **2,5% em cada cauda** ⇒ $c = t_{0,025;9}$.

Passo 3. Na tabela: $c = 2{,}262$, no lugar de 1,96.

Exemplo 1 — Resposta: com S, usamos a t

O tempo de resposta de uma API de pagamentos segue $X \sim N(250, 40^2)$. A equipe sorteia amostras de n requisições, não conhece σ e padroniza a média com S. Essa padronização segue $t(n - 1)$. Repetimos a simulação usando $\pm t_{0,025;\,n-1}$ no lugar de $\pm 1{,}96$:

n	c = $t_{0,025;n-1}$	Com S e ±1,96	Com S e ±c	Com σ e ±1,96
5	2,776	12,1%	**5,0%**	4,9%
10	2,262	8,1%	**5,0%**	5,0%
30	2,045	5,8%	**4,9%**	4,9%

Com S e o valor da t, **voltamos aos 5%**, como quem conhece σ.

Outro tipo de tabela t (Bussab)

- A Tabela V do Bussab é **bilateral**: dá t_c com $P(-t_c < t < t_c) = 1 - p$.
- A coluna p dessa tabela corresponde a $\alpha = p/2$ na nossa.
- Exemplo: $\nu = 6$, coluna 10% → $1{,}943 = t_{0{,}05;6}$; coluna 5% → $2{,}447 = t_{0{,}025;6}$ (Bussab, Exemplo 7.15).

Quando ν é grande

- Para $\nu > 120$, a t é praticamente a normal padrão (Bussab, Exemplo 7.15).
- Exemplo: $t_{0{,}025;120} = 1{,}980$ contra $z = 1{,}960$.

Quando usar a t e quando usar a qui-quadrado

Nesta aula, sorteamos uma amostra de n observações de uma população normal. A pergunta muda conforme o parâmetro que nos interessa:

- Se queremos informações sobre a média μ, com σ desconhecido: padronizamos $\bar{X}$ usando S no lugar de σ. Essa padronização segue a t de Student:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

Foi o caso da API de pagamentos (Exemplos 1 e 5).

Quando usar a t e quando usar a qui-quadrado

- Se queremos informações sobre a variância σ^2: comparamos S^2 com σ^2. Essa razão segue a qui-quadrado:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Foi o caso dos parafusos (Exemplo 3).

Próximas aulas: vamos usar as duas distribuições para construir intervalos de confiança (Aulas 18 e 19) e testes de hipótese (Aulas 20 a 22).

Resumo da aula: qual distribuição usar

- **Se o exercício envolve a média e você conhece σ:** use a normal padrão,

  $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n})$, e a tabela N(0,1).

- **Se o exercício envolve a média e você não conhece σ:** use a t de Student,

  $T = (\bar{X} - \mu)/(S/\sqrt{n})$, na linha $\nu = n - 1$ da tabela t.

- **Se o exercício envolve a variância (ou o desvio padrão):** use a qui-quadrado,

  $(n-1)S^2/\sigma^2$, na linha $\nu = n - 1$ da tabela χ^2.

Resumo da aula: como ler as tabelas

- **Se o exercício pede 95% no meio (duas caudas):** divida o que sobra entre as duas pontas e procure a coluna $\alpha = 0{,}025$.
- **Se o exercício pede o valor só ultrapassado em α (uma cauda):** procure direto a coluna α.
- **Se o exercício pede, na qui-quadrado, o valor com área α abaixo:** procure a coluna $1 - \alpha$, porque a tabela dá a área à direita (Exemplo 2, item b).
- **Se v passar de 120:** a t é praticamente a normal padrão; use a linha ∞ da tabela t.

Atividades referentes à aula

Leitura recomendada:

- Bussab & Morettin — Cap. 7: 7.7.2 e 7.7.3; Cap. 12: 12.9 e 12.10 (só a parte das distribuições)
- Montgomery & Runger — Cap. 8: 8.2.1 e 8.3 (até a definição dos percentis)
- Magalhães & Lima — Cap. 8: 8.3 (até a definição de T) e 8.5, p. 269 (apresentação do modelo χ^2)
- Morettin — Cap. 14: 14.1; Cap. 16: 16.1

Exercícios recomendados:

- Montgomery & Runger — Cap. 8: Exercícios 8.2.2 e 8.3.2 (percentis da t e da qui-quadrado)
- Magalhães & Lima — Cap. 8: Exercícios da Seção 8.3, n.º 1, e da Seção 8.5, n.º 1 (tabela t e tabela qui-quadrado)
- Lista de Exercícios 17

Pós-aula (em casa):

- O teste de desempenho da placa de vídeo — grupos de até 5 pessoas, uma folha por grupo; entregar no início da próxima aula