

CEA055 – Estatística e Probabilidade

Gabarito – Lista de Exercícios 17 – Teorema do Limite Central e Estimação Pontual

Aviso: este gabarito foi elaborado com o auxílio da IA Claude (Anthropic). Os cálculos foram verificados por execução em Python antes da publicação. As soluções mostram os principais passos, sem detalhamento exaustivo. Revise com atenção.

1. **Não viesado:** $E(\hat{\theta}) = \theta$ – o estimador "acerta em média", mesmo que uma amostra específica possa errar. **Consistente:** para qualquer margem $\epsilon > 0$, $\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| > \epsilon) = 0$ – a chance de o estimador errar por mais que ϵ vai a zero conforme a amostra cresce. Para um estimador não viesado, basta verificar que sua variância tende a zero quando $n \rightarrow \infty$.
2. (a) Verdadeira.
(b) Falsa – $E(\hat{p}) = p$, então $\hat{p}$ é não viesado.
(c) Verdadeira – não viesamento (acertar em média) e baixa variância (precisão) são propriedades independentes; um estimador pode ter uma sem a outra.
3. **Acurácia** mede o quão perto, em média, as estimativas ficam do valor-alvo (relacionada a não ter viés). **Precisão** mede o quão próximas as estimativas estão entre si (relacionada a ter baixa variância). Sim, um estimador pode ser acurado mas impreciso (não viesado, porém com alta variância) ou preciso mas não acurado (baixa variância, mas viesado, "errando sempre para o mesmo lado").
4. $\hat{p} = 280/500 = 0,56$.
5. $\text{Var}(\hat{p}) \approx \frac{0,56 \times 0,44}{500} \approx 0,000493$. Erro padrão $\approx \sqrt{0,000493} \approx 0,0222$.
6. Como n aparece no denominador, $\text{Var}(\hat{p}) = p(1-p)/n \rightarrow 0$ conforme $n \rightarrow \infty$. Como $\hat{p}$ é não viesado e sua variância tende a zero, a chance de $\hat{p}$ se afastar de p por mais que qualquer margem vai a zero: $\hat{p}$ é **consistente**.
7. $E(T_1) = \frac{1}{3}(\mu + \mu + \mu) = \mu$. $E(T_2) = E(X_1) = \mu$. Ambos não viesados.
 $\text{Var}(T_1) = \frac{1}{9}(\sigma^2 + \sigma^2 + \sigma^2) = \frac{\sigma^2}{3}$. $\text{Var}(T_2) = \text{Var}(X_1) = \sigma^2$.
 T_1 é mais eficiente, pois $\sigma^2/3 < \sigma^2$ (usa toda a informação da amostra, não só uma observação).
8. Erro padrão $= 8/\sqrt{64} = 8/8 = 1,0$.
9. (*Desafio*) (a) $E(T_1) = \mu$, $E(T_2) = \mu$, $E(T_3) = \frac{\mu + 2\mu + \mu + \mu}{5} = \frac{5\mu}{5} = \mu$. Todos são não viesados.
(b) $\text{Var}(T_1) = \frac{4\sigma^2}{16} = \frac{\sigma^2}{4} = 0,25\sigma^2$. $\text{Var}(T_2) = \frac{2\sigma^2}{4} = \frac{\sigma^2}{2} = 0,5\sigma^2$.
 $\text{Var}(T_3) = \frac{(1^2 + 2^2 + 1^2 + 1^2)\sigma^2}{25} = \frac{7\sigma^2}{25} = 0,28\sigma^2$.
(c) T_1 (a média amostral usual) tem a menor variância entre os três ($0,25\sigma^2 < 0,28\sigma^2 < 0,5\sigma^2$).
(d) Só podemos afirmar que T_1 é o melhor **entre os três comparados**. Existem infinitos outros estimadores não viesados possíveis que não testamos; embora seja um resultado conhecido (fora

do escopo desta lista) que a média amostral simples é, de fato, o estimador linear não viesado de variância mínima nesse tipo de problema, essa afirmação mais forte exigiria uma demonstração geral, não apenas a comparação com dois concorrentes específicos.

10. (*Bônus – Python, valores conferidos por execução real*) Simulação com $n = 300.000$ amostras ($\sigma^2 = 16$): variância empírica de $T_1 \approx 4,02$ (teórica: 4,0); de $T_2 \approx 8,02$ (teórica: 8,0); de $T_3 \approx 4,50$ (teórica: 4,48) – a ordem $T_1 < T_3 < T_2$ é exatamente a mesma concluída no item (c) do Desafio.