CEA055 – Estatística e Probabilidade

Correlação Linear e Modelo de Regressão Simples

Objetivos da aula:

- Calcular e interpretar o coeficiente de correlação linear amostral r.
- Compreender o modelo de regressão linear simples e suas suposições.
- Estimar os parâmetros do modelo pelo método dos mínimos quadrados.

Referências:

- Bussab, Morettin. Estatística Básica, 9ed — Cap. 16 (16.1, 16.2)
- Montgomery, Runger. Applied Statistics..., 7th ed — Cap. 11 (11.2, 11.3, 11.8)
- Magalhães, Lima. Noções de Probabilidade e Estatística, 5ed — Cap. 9 (9.5)

Professor: Marcos Goulart Lima

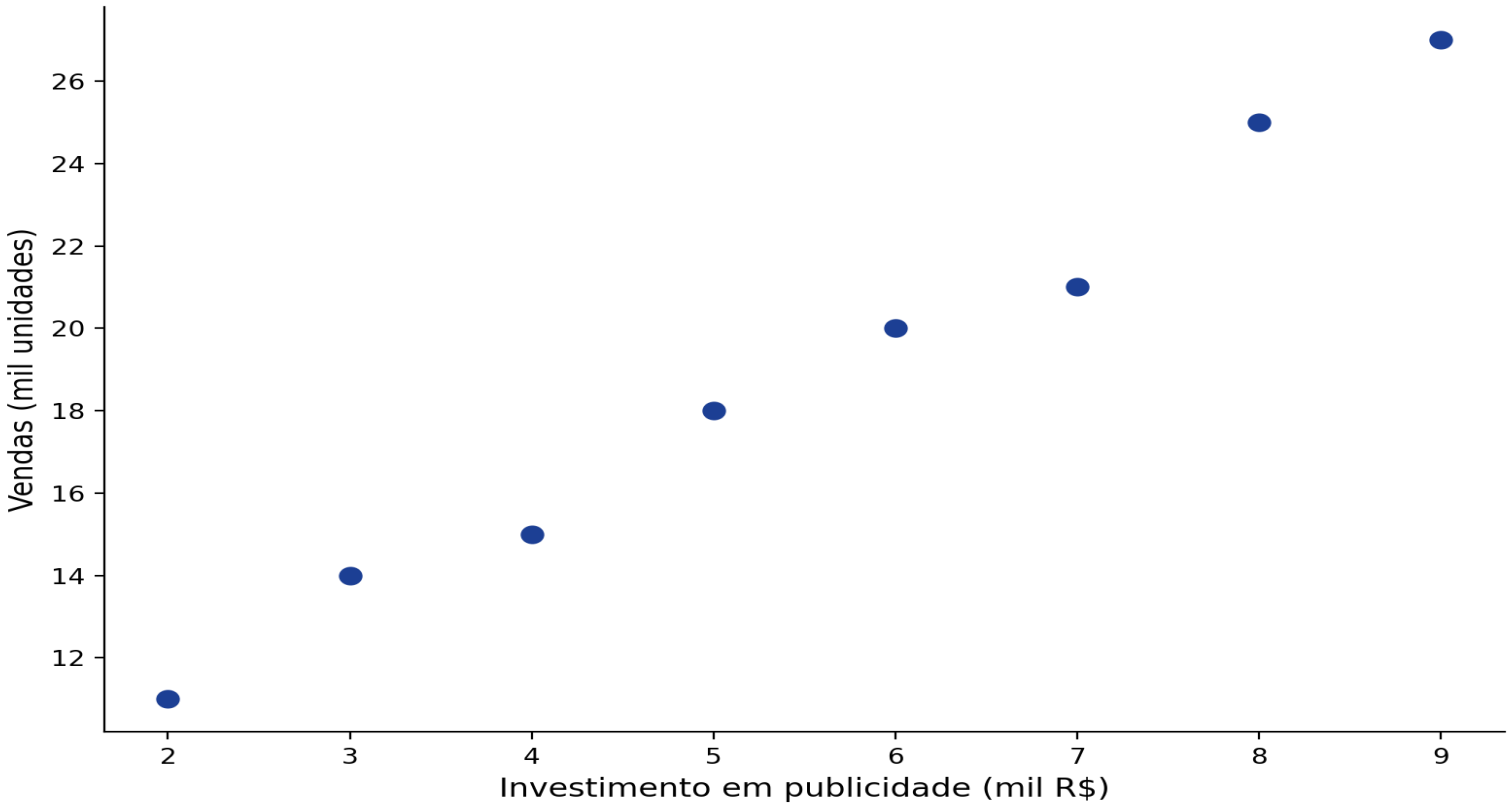
De associação a previsão

Na Aula 24, medimos a FORÇA da associação linear entre duas variáveis com ρ. Mas ainda não temos um MODELO que descreva essa relação.

- Hoje damos o passo seguinte: ajustar uma reta que resuma a relação entre X e Y, e que permita PREVER Y a partir de X.
- Exemplo que usaremos: X = investimento em publicidade (mil R$), Y = vendas (mil unidades), em 8 lojas de uma rede.

O primeiro passo: o diagrama de dispersão

Antes de qualquer cálculo, sempre visualize os dados:



Coeficiente de correlação amostral r

Com uma amostra de n pares (x_i, y_i), estimamos ρ (Aula 24) pelo coeficiente amostral r:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Interpretando r

- Mesma lógica de ρ (Aula 24): $-1 \leq r \leq +1$, sinal indica direção, magnitude indica força da associação LINEAR.
- r é uma ESTIMATIVA de ρ calculada a partir de uma amostra específica — outra amostra daria um r ligeiramente diferente.
- Faixas usadas informalmente: $|r| > 0{,}7$ costuma ser considerado forte; entre 0,3 e 0,7, moderado; abaixo de 0,3, fraco (não são regras rígidas).

Calculando r no exemplo da publicidade

Dados (n=8): X = 2,3,4,5,6,7,8,9 (mil R$); Y = 11,14,15,18,20,21,25,27 (mil unidades).

- $\bar{X} = 5{,}5$; $\bar{Y} = 18{,}875$.
- $S_{xx} = \Sigma(x_i - \bar{X})^2 = 42{,}0$; $S_{yy} = \Sigma(y_i - \bar{Y})^2 = 210{,}875$; $S_{xy} = \Sigma(x_i - \bar{X})(y_i - \bar{Y}) = 93{,}5$.
- $r = 93{,}5 / \sqrt{(42{,}0 \times 210{,}875)} = 93{,}5 / 94{,}10 = 0{,}994$.

Interpretação: correlação linear POSITIVA muito forte — mais investimento em publicidade está fortemente associado a mais vendas.

O modelo de regressão linear simples

Um passo além da correlação: propor um modelo que descreve Y em função de X:

$$Y_i = \alpha + \beta X_i + e_i$$

- α (intercepto) e β (inclinação) são parâmetros desconhecidos, a estimar a partir dos dados.
- e_i é o erro aleatório — tudo que a reta não explica (variação individual de cada ponto).

Suposições do modelo

- X é considerada fixa (controlada), sem erro de medida — só Y tem componente aleatório.
- Os erros e_i têm média zero: $E(e_i|x) = 0$ — a reta captura a tendência central corretamente.
- Os erros têm variância constante em torno da reta, para qualquer valor de X (homocedasticidade).
- Os erros não são correlacionados entre si.

Vamos verificar essas suposições na prática, com gráficos de resíduos, na Aula 26.

Interpretando α e β

- α (intercepto): valor esperado de Y quando X = 0. Nem sempre tem interpretação prática direta (ex.: publicidade = 0 pode estar fora da faixa observada).
- β (inclinação): o quanto Y muda, EM MÉDIA, para cada aumento de 1 unidade em X.
- No nosso exemplo: se β ≈ 2,2, cada mil R$ a mais em publicidade está associado a, em média, 2,2 mil unidades a mais vendidas.

O método dos mínimos quadrados

- Precisamos escolher os “melhores” valores de α e β para a reta. Mas “melhor” segundo qual critério?
- Ideia: minimizar a soma dos quadrados das distâncias verticais entre os pontos observados e a reta (os resíduos).
- Por que ao quadrado? Para que desvios positivos e negativos não se cancelem, e para penalizar mais os erros grandes.

Esse critério tem solução matemática exata, dada pelas fórmulas a seguir.

Os estimadores de mínimos quadrados

A inclinação e o intercepto que minimizam a soma dos quadrados dos resíduos são:

$$\hat{\beta} = \frac{s_{xy}}{s_{xx}} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

$$\hat{\alpha} = \bar{y} - \hat{\beta}\,\bar{x}$$

Ajustando a reta ao exemplo da publicidade

Já temos $S_{xx} = 42{,}0$ e $S_{xy} = 93{,}5$ (slide anterior). Calculamos:

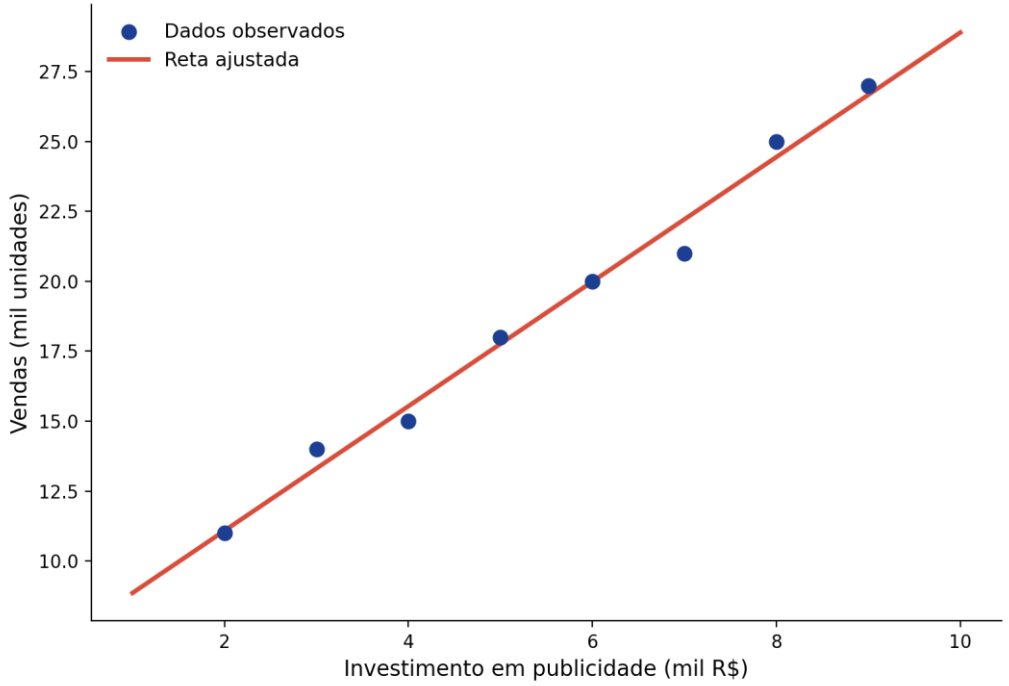
- $\beta = S_{xy} / S_{xx} = 93{,}5 / 42{,}0 = 2{,}226$.
- $\hat{\alpha} = \bar{Y} - \beta \cdot \bar{X} = 18{,}875 - 2{,}226 \times 5{,}5 = 18{,}875 - 12{,}244 = 6{,}631$.

Reta ajustada: $\hat{Y} = 6{,}631 + 2{,}226 \cdot X$

A reta ajustada

$\hat{Y} = 6{,}631 + 2{,}226 \cdot X$

- Cada mil R$ investido em publicidade está associado a um aumento médio de 2.226 unidades vendidas.
- O intercepto (6,631) seria a venda esperada sem publicidade nenhuma — mas atenção: X=0 está fora da faixa observada (2 a 9), então essa leitura deve ser vista com cautela.



Como r e β se relacionam

- r e β sempre têm o MESMO SINAL — ambos vêm do mesmo numerador S_{xy}.
- Mas são coisas diferentes: r não tem unidade (é adimensional); β tem unidade de Y por unidade de X (aqui, mil unidades vendidas por mil R$ investido).
- Relação exata: $\beta = r \times (S_y/S_x)$, em que S_y e S_x são os desvios padrão amostrais de Y e X.

Em resumo: r mede a FORÇA da relação; β mede o IMPACTO prático de X sobre Y, em suas próprias unidades.

Usando o modelo para prever

- Com a reta ajustada, podemos prever Y para um novo valor de X, dentro da faixa observada.
- Exemplo: quanto esperamos vender com X = 6,5 mil R$ de publicidade?
- $\hat{Y} = 6{,}631 + 2{,}226 \times 6{,}5 = 6{,}631 + 14{,}469 = 21{,}10$ mil unidades.

Essa previsão é uma estimativa da média de Y para X=6,5 — vendas reais variam em torno desse valor, devido ao erro aleatório e_i.

Cuidado com a extrapolação

- O modelo só foi validado dentro da faixa observada de X (no exemplo, de 2 a 9 mil R$).
- Prever fora dessa faixa (ex.: X = 50 mil R$) é arriscado — não temos garantia de que a relação linear continua válida tão longe dos dados observados.
- Investimentos muito altos podem ter retornos decrescentes (saturação de mercado) — um padrão que uma reta ajustada a dados pequenos não conseguiria capturar.

Regra prática: use o modelo para interpolar (dentro da faixa), com cautela redobrada ao extrapolar.

Resumo da aula

- r mede a força e direção da associação linear entre X e Y, numa amostra.
- O modelo $Y = \alpha + \beta X + e$ propõe uma relação linear entre as duas variáveis, com erro aleatório.
- O método dos mínimos quadrados fornece as fórmulas de $\hat{\alpha}$ e β que melhor ajustam a reta aos dados.
- A reta ajustada permite interpolar previsões de Y, com cautela ao extrapolar.

Próxima aula: como avaliar se o modelo ajustado é realmente bom, usando resíduos e o coeficiente de determinação R^2.

Atividades referentes à aula

Leitura recomendada:

- Bussab & Morettin — Cap. 16: 16.1, 16.2
- Montgomery & Runger — Cap. 11: 11.2, 11.3, 11.8
- Magalhães & Lima — Cap. 9: 9.5

Exercícios recomendados:

- Usando os mesmos dados do exemplo, calcule a previsão de vendas para X = 4,5 mil R$.
- Colete (ou invente) 6 pares de dados de duas variáveis do seu cotidiano e ajuste uma reta de mínimos quadrados.