

CEA055 – Estatística e Probabilidade

Gabarito – Lista de Exercícios 25 – Covariância e Correlação

Aviso: este gabarito foi elaborado com o auxílio da IA Claude (Anthropic). Os cálculos foram verificados por execução em Python antes da publicação, e o resultado do Desafio foi confirmado também por simulação de 500.000 valores. As soluções mostram os principais passos, sem detalhamento exaustivo. Revise com atenção.

1. A covariância mede a direção e a "magnitude bruta" da associação linear, mas sua escala depende das unidades de X e Y (dificultando comparações). O coeficiente de correlação $\rho = \text{Cov}(X, Y) / (\sigma_X \sigma_Y)$ é uma versão "padronizada" da covariância, sempre entre -1 e 1 , o que permite comparar a força de associações mesmo entre variáveis com escalas muito diferentes.
2. (a) Falsa – é a implicação contrária que vale sempre ($\text{independência} \Rightarrow \text{Cov} = 0$); $\text{Cov} = 0$ não garante independência.
(b) Verdadeira.
(c) Verdadeira – é o resultado visto em aula ("covariância zero $\neq$ independência": independência implica covariância zero, mas não o contrário).
3. Por exemplo: escolha um ponto ao acaso sobre uma circunferência de raio 1 centrada na origem, e sejam X a sua coordenada horizontal e Y a vertical. Pela simetria do círculo, não há tendência linear (a covariância é zero), mas as variáveis são dependentes: se X está perto de 1, Y é obrigatoriamente perto de 0 (pois $X^2 + Y^2 = 1$). Qualquer relação "curva" e simétrica serve – o Desafio mostra outra, com contas.
4. $E(X) = 1(0,25) + 2(0,30) + 3(0,45) = 2,2$. $E(Y) = 10(0,40) + 20(0,60) = 16,0$.
 $E(XY) = 1(10)(0,10) + 1(20)(0,15) + 2(10)(0,20) + 2(20)(0,10) + 3(10)(0,10) + 3(20)(0,35) = 36,0$.
 $\text{Cov}(X, Y) = 36,0 - (2,2)(16,0) = 0,8$.
5. $\text{Var}(X) = 0,66$; $\text{Var}(Y) = 24,0$. $\rho = \frac{0,8}{\sqrt{0,66 \times 24,0}} \approx 0,201$ – uma correlação positiva, mas fraca.
6. $\text{Var}(X + Y) = 0,66 + 24,0 + 2(0,8) = 26,26$.
7. $\text{Var}(X - Y) = 0,66 + 24,0 - 2(0,8) = 23,06$. Os valores são diferentes porque a covariância entra com sinal oposto nas duas fórmulas: quando $\text{Cov}(X, Y) > 0$, somar as variáveis "acumula" a associação positiva (aumentando a variância da soma), enquanto subtrair "cancela" parte dela (diminuindo a variância da diferença).
8. (*Desafio*) (a) $P(X = -1, Y = 1) = 1/3$; $P(X = 0, Y = 0) = 1/3$; $P(X = 1, Y = 1) = 1/3$; todos os demais pares têm probabilidade zero.
(b) $E(X) = (-1 + 0 + 1)/3 = 0$. $E(Y) = 0(1/3) + 1(2/3) = 2/3$. $E(XY) = (-1)(1)(1/3) + 0(0)(1/3) + (1)(1)(1/3) = 0$.
(c) $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0 - 0 \times (2/3) = 0$. Sim, é surpreendente à primeira vista – Y é completamente determinado por X , mas a covariância é exatamente zero!
(d) Por exemplo, no par $(-1, 0)$: $p(-1, 0) = 0$, mas $p_X(-1) \cdot p_Y(0) = (1/3)(1/3) = 1/9 \neq 0$. Como a igualdade falha, X e Y não são independentes.

(e) A covariância (e a correlação) só captura relações **lineares** entre as variáveis. A relação $Y = X^2$ é uma parábola – fortemente dependente, mas simétrica em torno de $X = 0$, de forma que os desvios positivos e negativos de X se cancelam exatamente na covariância. Isso ensina que covariância/correlação zero não significa ausência de relação – só significa ausência de relação **linear**.

9. (*Bônus – Python, valores conferidos por execução real*) Simulação com $n = 500.000$: covariância empírica $\approx -0,00013$ e correlação empírica $\approx -0,00034$ – ambas essencialmente zero, confirmando o resultado teórico do item (c). O gráfico de dispersão mostra claramente uma parábola (relação forte e determinística), evidenciando que a correlação "não enxerga" esse tipo de padrão por não ser linear.