

CEA055 – Estatística e Probabilidade

Lista de Exercícios 27 – Avaliação do Modelo de Regressão (resíduos, decomposição da variação e R^2)

Aviso: esta lista de exercícios foi elaborada com o auxílio da IA Claude (Anthropic). Os problemas são originais (não copiados de nenhum livro-texto). As fórmulas e convenções usadas foram conferidas contra a bibliografia da disciplina. Revise as respostas com atenção – como em qualquer material gerado com apoio de IA, pode haver imprecisões.

Parte 1 – Revisão de conceitos

1. O que representam SQT , SQR e SQE na decomposição da variação total de y ? Como eles se relacionam (escreva a fórmula)?
2. Classifique cada afirmação como Verdadeira ou Falsa, **justificando** em uma frase:
 - (a) $R^2 = SQR/SQT$ mede a proporção da variação total de y que é "explicada" pelo modelo de regressão.
 - (b) Um R^2 próximo de 1 significa necessariamente que existe uma relação de causa e efeito entre x e y .
 - (c) Na regressão linear simples (uma única variável explicativa), o R^2 é igual ao quadrado do coeficiente de correlação r .
3. Por que analisar o padrão dos resíduos (por exemplo, num gráfico de resíduos contra x) é importante para avaliar se o modelo linear é adequado, além de simplesmente olhar para o valor de R^2 ?

Parte 2 – Resolução (fórmulas e cálculos)

Retome os dados da Lista 26 (horas de estudo x e nota y de 5 alunos), cuja reta ajustada foi $\hat{y} = 41,5 + 3,75x$, com resíduos 1,0; -1,5; 1,0; -1,5; 1,0 (para $x = 2, 4, 6, 8, 10$, respectivamente).

4. Calcule $SQT = \sum (y_i - \bar{y})^2$ (lembrando que $\bar{y} = 64$).
5. Usando os resíduos já dados, calcule $SQE = \sum \hat{e}_i^2$.
6. Calcule $SQR = SQT - SQE$, e a partir daí calcule $R^2 = SQR/SQT$. Compare com o quadrado do coeficiente de correlação $r \approx 0,9934$ calculado na Lista 26.
7. Esboce, à mão, o gráfico de resíduos (valor de x no eixo horizontal, resíduo no eixo vertical, com uma linha horizontal em zero). Os pontos parecem espalhados em torno de zero, sem uma curva sistemática? O que isso indica sobre o modelo linear para esses dados?

Parte 3 – Desafio

Desafio

8. Um novo conjunto de dados relaciona horas semanais de exercício físico (x) com uma métrica de condicionamento (y) de 6 pessoas:

$$x : 1, 2, 3, 4, 5, 6 \quad y : 10, 14, 20, 22, 24, 24$$

- (a) Ajuste a reta de mínimos quadrados (calcule $\hat{\beta}$ e $\hat{\alpha}$).
- (b) Calcule SQT , SQE e SQR para esse ajuste.
- (c) Calcule R^2 . Compare com o R^2 obtido no Exercício 6 (dados de horas de estudo x nota) – qual dos dois modelos "explica" proporcionalmente mais da variação de y ?
- (d) Calcule os resíduos $\hat{e}_i = y_i - \hat{y}_i$ para os 6 pontos, na ordem de x crescente. Observando os **sinais** dos resíduos em sequência, existe algum padrão sistemático (não aleatório)? O que esse padrão sugere sobre a adequação do modelo linear para esses dados especificamente (dica: pense se o crescimento de y parece "desacelerar" à medida que x aumenta)?

Parte 4 – Desafio bônus (opcional, não vale nota)

Bônus – Python no Google Colab

9. Exercício opcional, para quem quiser praticar programação. Não precisa instalar nada – roda direto no [Google Colab](#).

Vamos confirmar os cálculos do Desafio (Exercício 8) e visualizar o padrão dos resíduos.

- (a) Ajuste o modelo e calcule a decomposição da variação "na mão" (com `numpy`):

```
import numpy as np

x = np.array([1, 2, 3, 4, 5, 6])
y = np.array([10, 14, 20, 22, 24, 24])

xbar, ybar = x.mean(), y.mean()
beta = np.sum((x - xbar) * (y - ybar)) / np.sum((x - xbar)**2)
alpha = ybar - beta * xbar

yhat = alpha + beta * x
residuos = y - yhat

SQT = np.sum((y - ybar)**2)
SQE = np.sum(residuos**2)
SQR = SQT - SQE
R2 = SQR / SQT

print("beta:", beta, "alpha:", alpha)
print("SQT:", SQT, "SQR:", SQR, "SQE:", SQE, "R2:", R2)
```

- (b) Compare os valores obtidos com os calculados manualmente no Desafio. Eles batem?
- (c) Construa um gráfico de resíduos (resíduo no eixo y , valor de x no eixo x), com uma

linha horizontal em zero para referência:

```
import matplotlib.pyplot as plt

plt.scatter(x, residuos)
plt.axhline(0, color="red", linestyle="--")
plt.xlabel("x (horas de exercicio)")
plt.ylabel("residuo")
plt.show()
```

O padrão visual (os pontos formam uma curva sistemática, subindo e depois descendo, em vez de estarem espalhados aleatoriamente ao redor de zero) confirma a suspeita de não linearidade discutida no item (d) do Desafio?