CEA055 – Estatística e Probabilidade

Estatística Descritiva I

UFOP
Universidade Federal de Ouro Preto

Objetivos do aula:

- Conhecer os tipos de variáveis e algumas representações gráficas.

Referências:

- Bussab, Morettin. **Estatística Básica**, 9ed — Cap. 2 (2.1 a 2.4) e Cap. 3 (3.1)
- Montgomery, Runger. **Applied Statistics and Probability for Engineers**, 7th ed — Cap. 6 (6.1 a 6.3)
- Magalhães, Lima. **Noções de Probabilidade e Estatística**, 5ed — Cap. 1 (1.2)

Vamos introduzir o conceito de **variável** com um exemplo:

Exemplo: Um pesquisador está interessado em fazer um levantamento sobre alguns aspectos socioeconômicos dos empregados da seção de orçamentos da Companhia MB. Usando informações obtidas do departamento de pessoal, ele elaborou a Tabela 2.1. Essa tabela é chamada planilha de dados.

N	Estado Civil	Grau de Instrução	N de Filhos	Salario (x Sal Min)	Idade (anos)	Idade (Meses)	Região de Procedência
1	solteiro	ensino fundamental		4,00	26	3	interior
2	casado	ensino fundamental	1	4,56	32	10	capital
3	casado	ensino fundamental	2	5,25	36	5	capital
4	solteiro	ensino médio		5,73	20	10	outra
5	solteiro	ensino fundamental		6,26	40	7	outra
6	casado	ensino fundamental	0	6,66	28	0	interior
7	solteiro	ensino fundamental		6,86	41	0	interior
8	solteiro	ensino fundamental		7,39	43	4	capital
9	casado	ensino médio	1	7,59	34	10	capital
10	solteiro	ensino médio		7,44	23	6	outra
11	casado	ensino médio	2	8,12	33	6	interior
12	solteiro	ensino fundamental		8,46	27	11	capital

Variáveis da tabela:

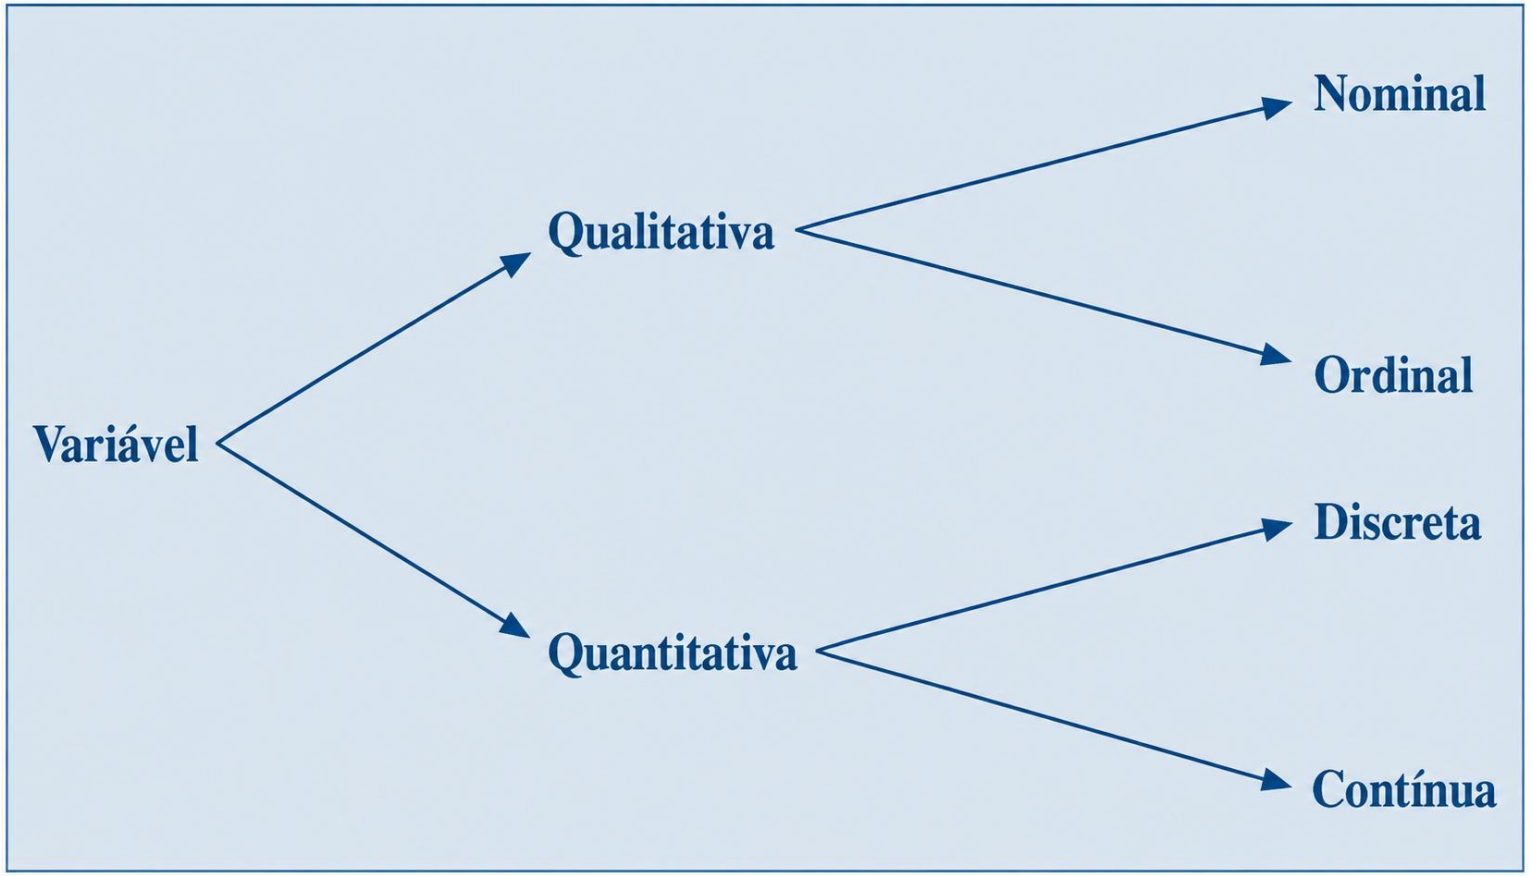
As variáveis podem ser identificadas na primeira linha da tabela.

- Estado Civil, Grau de Instrução, N de Filhos, Salario (x Sal Min), Idade (anos), Idade (Meses), Região de Procedência

Os números referentes a cada variável são chamados de realizações.

- Atribuiremos a cada variável uma letra maiúscula $(X, Y, Z, W, \dots)$

As variáveis se dividem em tipos:



Variáveis qualitativas

- **Nominal**
  - Ex.: cor dos olhos, comida preferida, etc.

- **Ordinal**
  - Grau de escolaridade, patentes do exército, etc.

Algumas variáveis nominais são dicotômicas, ou seja, só podem ocorrer duas realizações (sucesso e fracasso).

Variáveis quantitativas

- **Discreta**
  - Quando as realizações possíveis pertencem a um conjunto finito ou enumerável.

- **Contínua**
  - Quando as realizações pertencem a um intervalo em $\mathbb{R}$.

Distribuições de frequências

- Ao estudarmos uma variável, é importante saber a frequência que suas realizações acontecem.
- Estudar a distribuição de frequências das realizações nos dará uma ideia do comportamento da variável.

Exemplo de tabela de distribuição de frequências

Grau de instrução	Frequência ni	Proporção fi	Porcentagem 100 fi
Fundamental	12	0,3333	33,33
Médio	18	0,5000	50,00
Superior	6	0,1667	16,67
Total	**36**	**1,0000**	**100,00**

- Número de realizações ou frequência: n_i
- Proporção: $f_i = \frac{n_i}{total}$
- Porcentagem: $100 * f_i$

Uma vantagem em utilizar a proporção para representar distribuições de frequência é comparar dados de tamanhos diferentes.

Tabela 2.2: Frequências e porcentagens dos 36 empregados da seção de orçamentos da Companhia MB segundo o grau de instrução.

Grau de instrução	Freq ni	Proporção fi	Porcentagem 100 fi
Fundamental	12	0,3333	33,33
Médio	18	0,5000	50,00
Superior	6	0,1667	16,67
Total	**36**	**1,0000**	**100,00**

Fonte: Tabela 2.1.

Tabela 2.3: Frequências e porcentagens dos 2.000 empregados da Companhia MB, segundo o grau de instrução.

Grau de instrução	Freq ni	Porcentagem 100 fi
Fundamental	650	32,50
Médio	1.020	51,00
Superior	330	16,50
Total	**2.000**	**100,00**

Fonte: Dados hipotéticos.

Exemplo com variáveis contínuas.

Quando queremos avaliar a frequencia de uma variável contínua, precisamos dividir as realizações em classes e contar o número de realizações em cada classe.

Tabela 2.4: Frequências e porcentagens dos 36 empregados da seção de orçamentos da Companhia MB por faixa de salário.

Classe de salários	Freqüência ni	Porcentagem 100 fi
4,00 ⊢ 8,00	10	27,78
8,00 ⊢ 12,00	12	33,33
12,00 ⊢ 16,00	8	22,22
16,00 ⊢ 20,00	5	13,89
20,00 ⊢ 24,00	1	2,78
Total	**36**	**100,00**

Gráficos

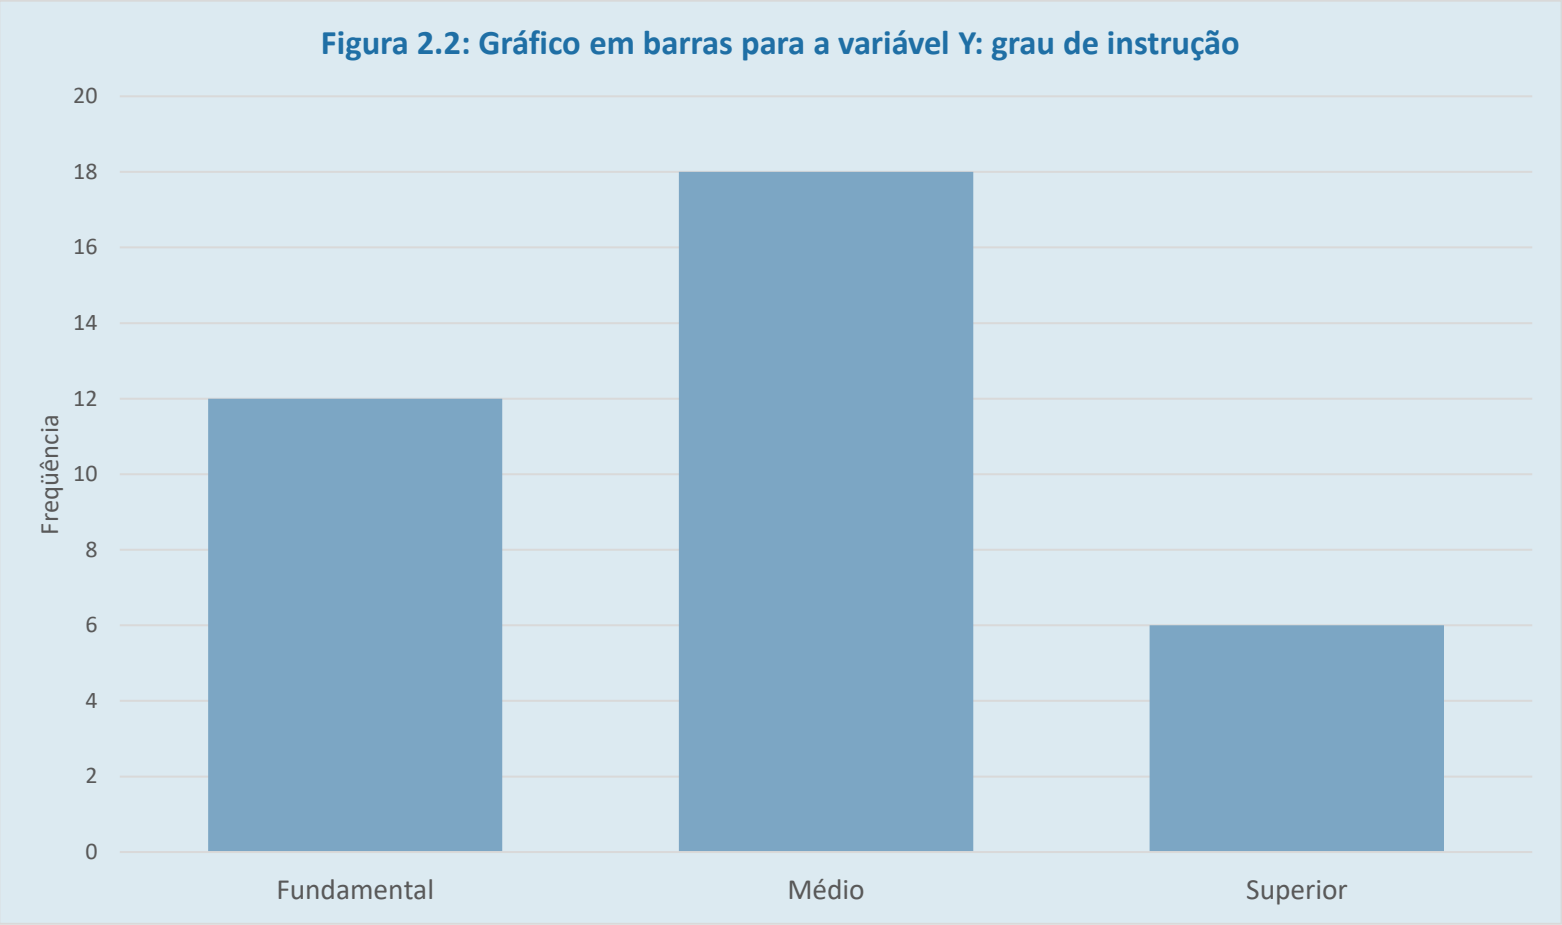
Usamos representações gráficas para melhorar a visualização da distribuição (ou comportamento) de uma variável.

A vantagem desse tipo de representação é a possibilidade de uma interpretação mais rápida dos dados.

A seguir veremos alguns exemplos de gráficos.

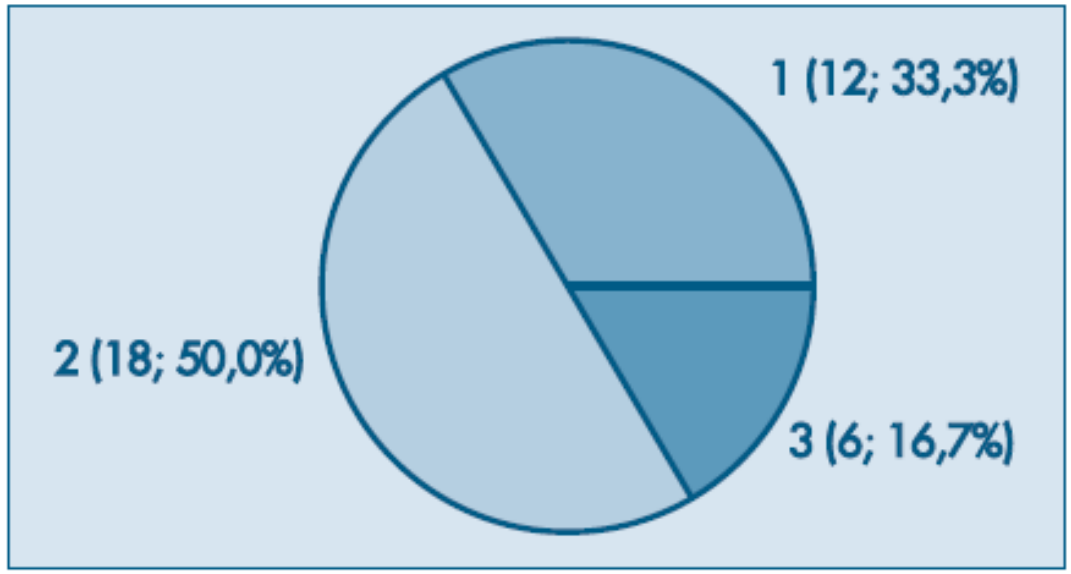
Tipos de gráficos

- Barras.



- Setores (ou pizza).

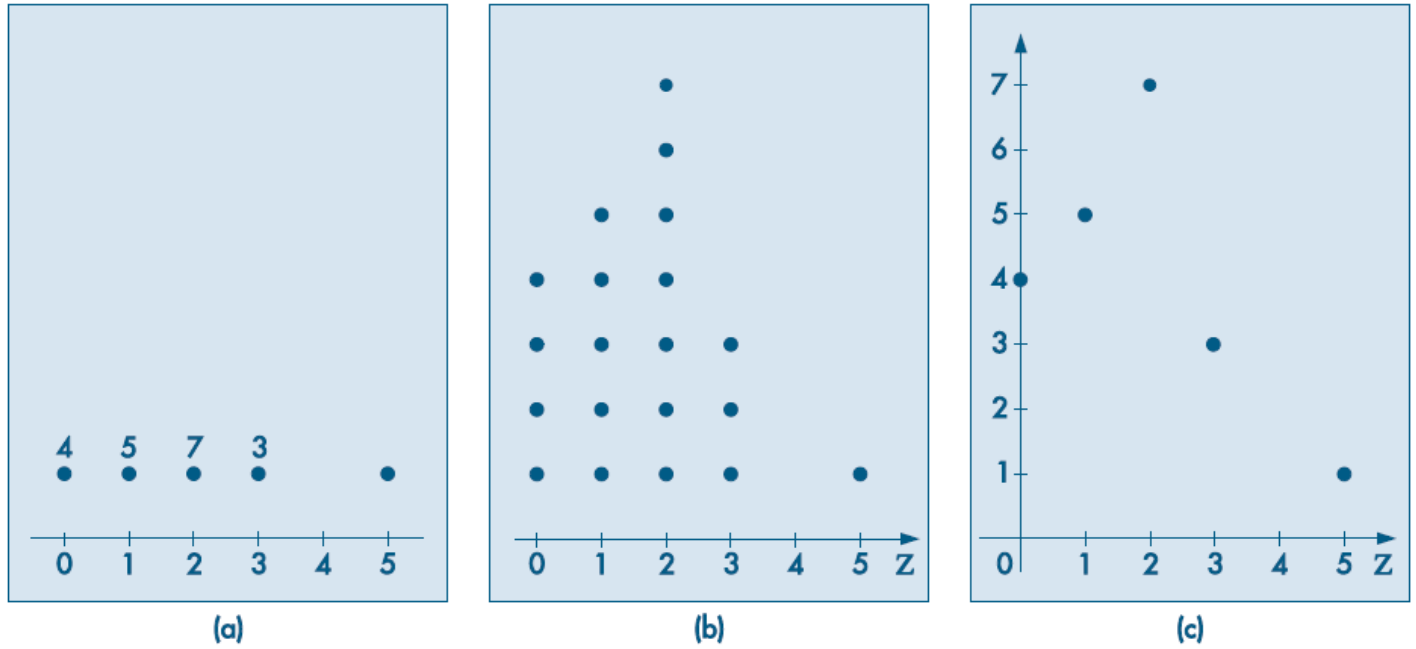
Figura 2.3: Gráfico em setores para a variável *Y*: grau de instrução.



1 = Fundamental, 2 = Médio e 3 = Superior

- Dispersão unidimensional

Figura 2.5: Gráficos de dispersão unidimensionais para a variável Z: número de filhos.

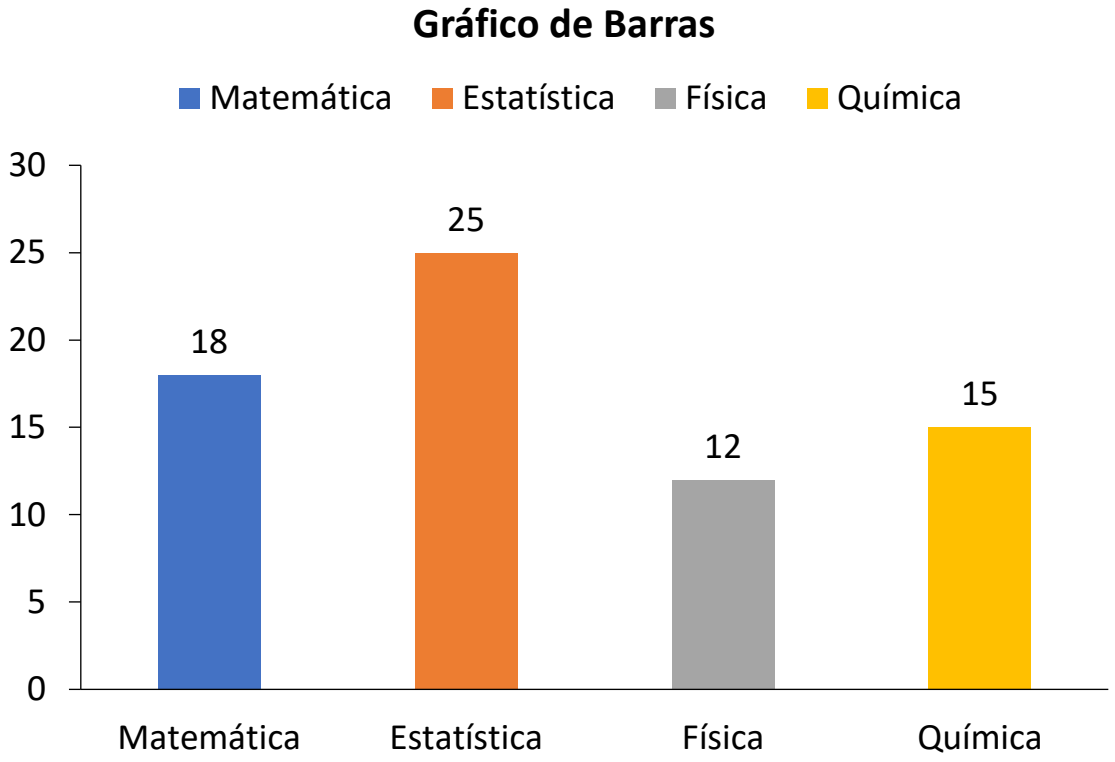


- Histograma

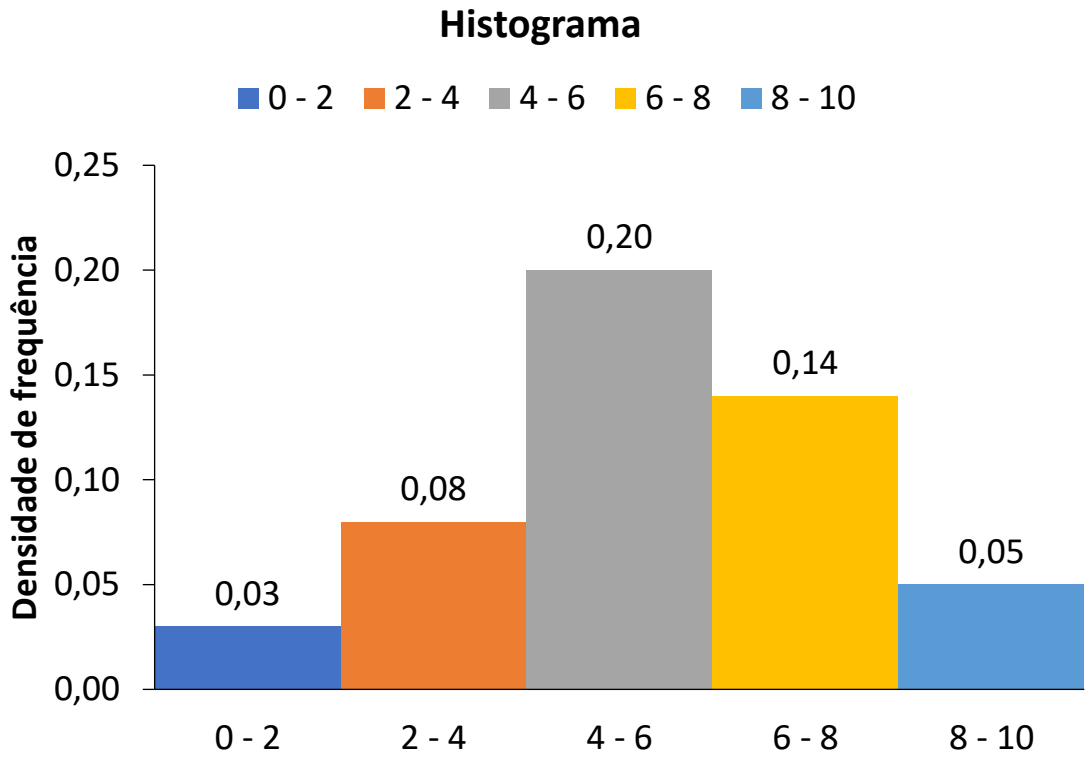
O histograma é um gráfico de barras tal que a largura representa um intervalo de classe e a área é proporcional à frequência (**dados quantitativos contínuos)**.

Diferença: no gráfico de barras comum, as barras têm largura igual e representam categorias (dados qualitativos);

Gráfico de Barras vs. Histograma



Dados qualitativos (categorias). Barras com largura igual e separadas por espaços.

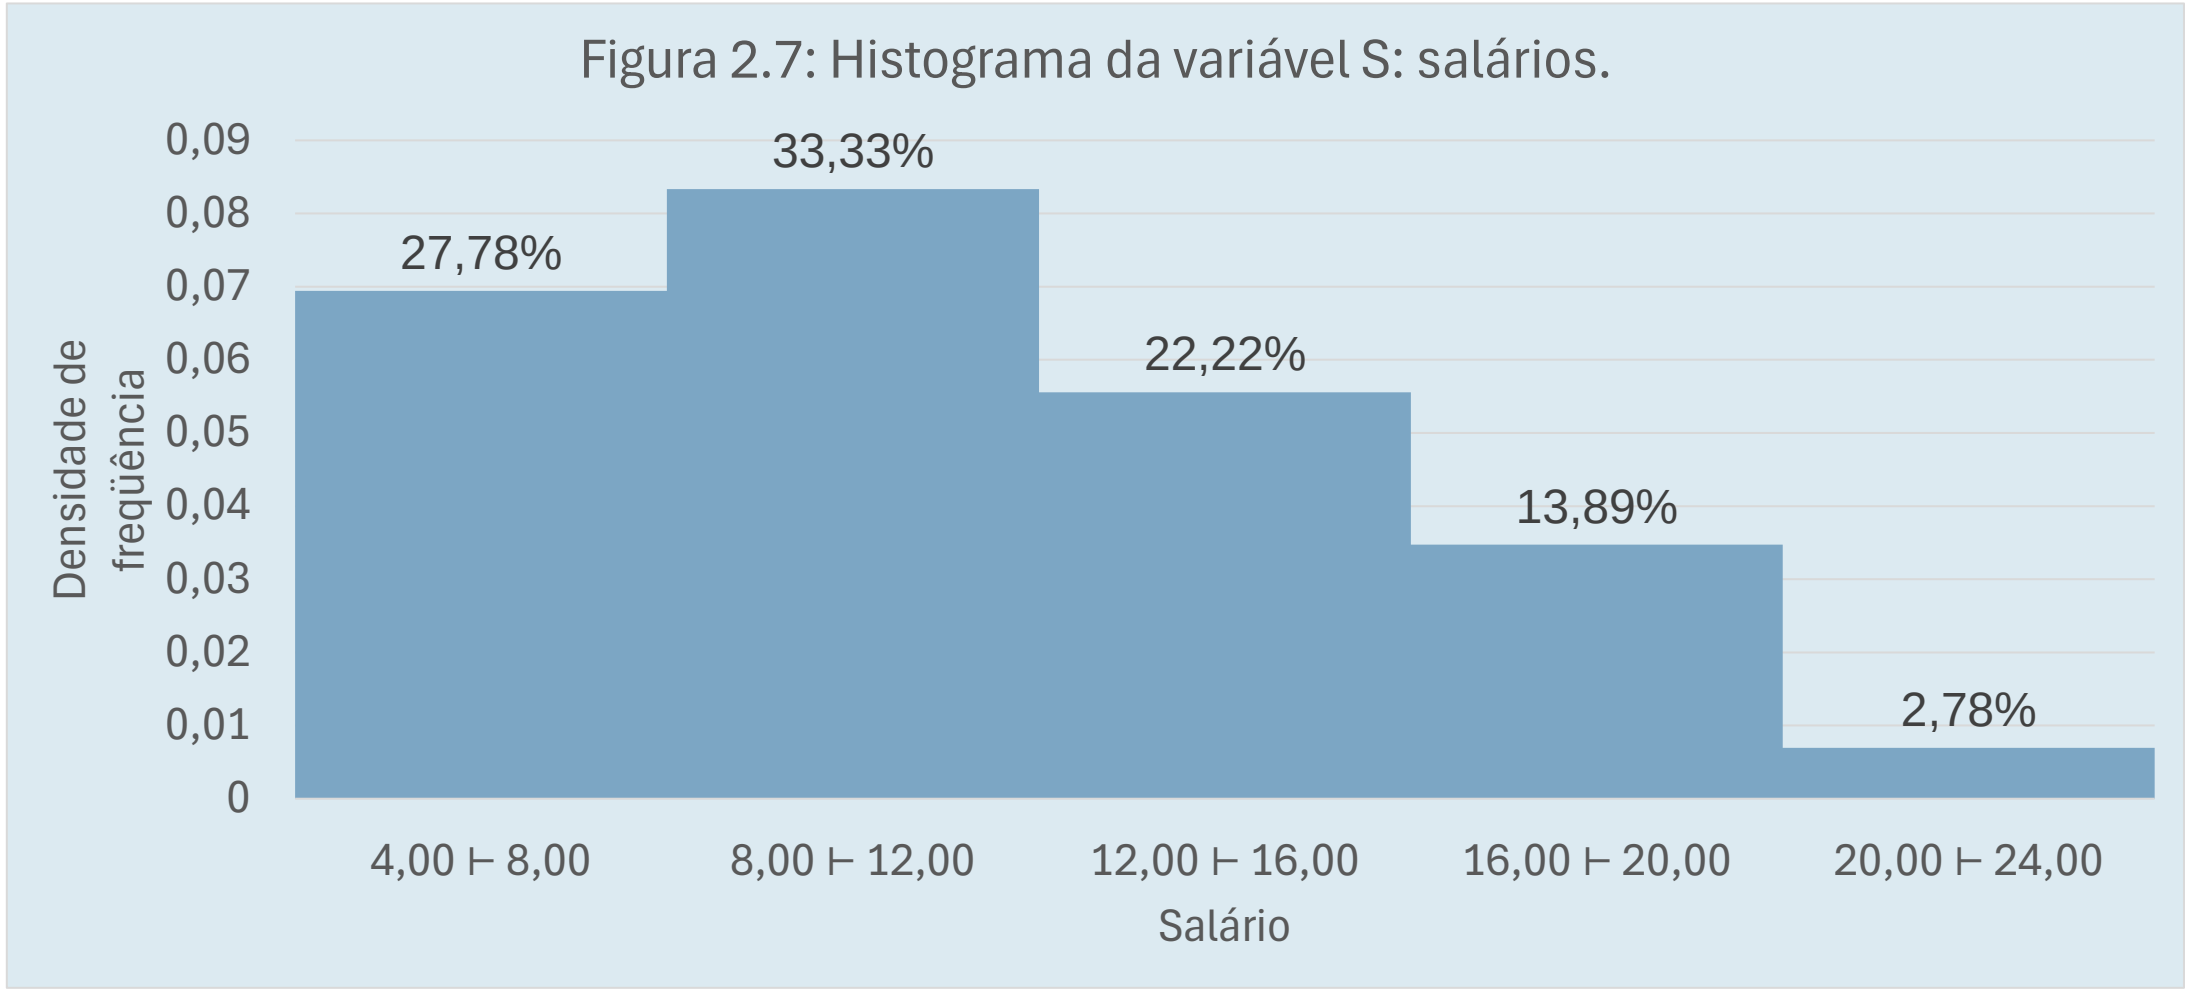


Dados quantitativos contínuos (intervalos de classe). Altura = densidade de frequência (fi/n dividido pela amplitude); área total dos retângulos = 1.

Cálculos para se fazer o histograma:

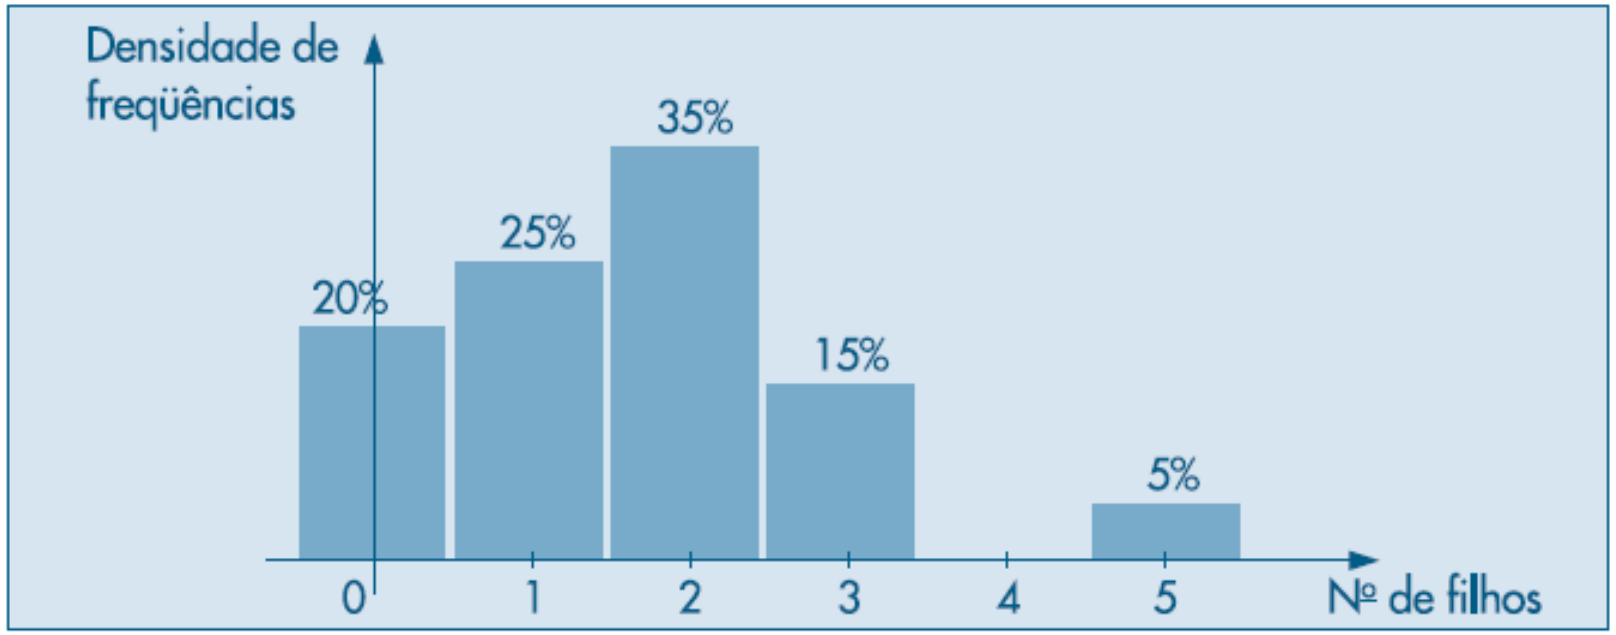
- as bases são proporcionais aos intervalos das classes
- a área de cada retângulo é proporcional à respectiva frequência.
- Se a base do intervalo i é denotada por Δ_i, então a altura do retângulo correspondente é proporcional a $\frac{f_i}{\Delta_i}$.
- A soma das áreas dos retângulos será igual a 1.

Tente fazer os cálculos e chegar no seguinte histograma (casa)

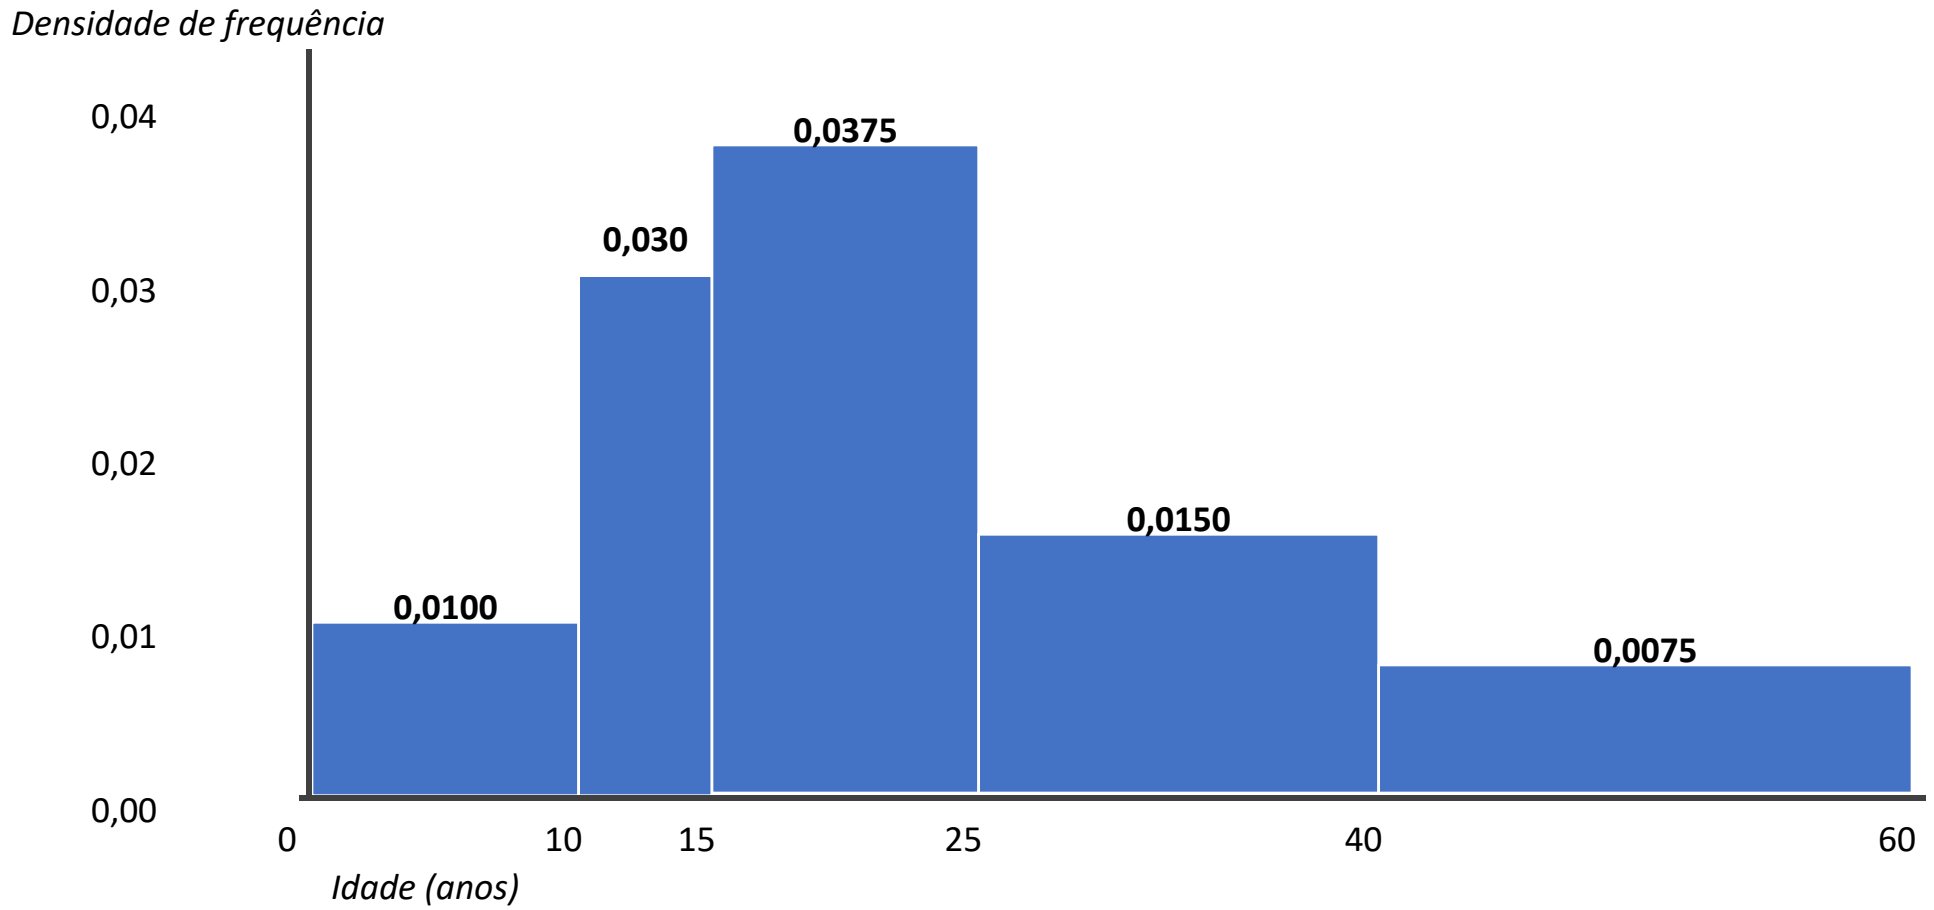


Também podemos usar o histograma para variáveis discretas. Basta adaptar as realizações como intervalos de tamanho iguais

Figura 2.8: Histograma da variável Z: número de filhos.



Histograma com Classes de Amplitudes Diferentes



Altura = densidade de frequência (fi/n ÷ Δi), não frequência absoluta — larguras maiores podem ter alturas menores.

Tipos de gráficos

- Ramo-e-folhas

Um gráfico do tipo ramo-e-folhas é uma tabela com uma linha vertical separando a primeira coluna das demais. Cada ocorrência da variável é dividida em duas informações:

- O ramo (primeira coluna).
- As folhas (linhas). É o complemento da informação colocada a direita do ramo.

Ramo-e-folhas

Figura 2.9: Ramo-e-folhas para a variável S: salários.

4	00 56
5	25 73
6	26 66 86
7	39 44 59
8	12 46 74 95
9	13 35 77 80
10	53 76
11	06 59
12	00 79
13	23 60 85
14	69 71
15	99
16	22 61
17	26
18	75
19	40
20	
21	
22	
23	30

Exemplo. Faça um gráfico de Ramo-e-folhas dos dados abaixo

Exemplo 2.9. Os dados abaixo referem-se à dureza de 30 peças de alumínio (Hoaglin, Mosteller e Tukey, 1983, pág. 13).									
53,0	70,2	84,3	69,5	77,8	87,5	53,4	82,5	67,3	54,1
70,5	71,4	95,4	51,1	74,4	55,7	63,5	85,8	53,5	64,3
82,7	78,5	55,7	69,1	72,3	59,5	55,3	73,0	52,4	50,7

O primeiro passo é organizar os dados em ordem crescente:

50,7 — 51,1 — 52,4 — 53,0 — 53,4 — 53,5 — 54,1 — 55,3 — 55,7 — 55,7 — 59,5

63,5 — 64,3 — 67,3 — 69,1 — 69,5

70,2 — 70,5 — 71,4 — 72,3 — 73,0 — 74,4 — 77,8 — 78,5

82,5 — 82,7 — 84,3 — 85,8 — 87,5

95,4

Agora é só formatar os dados:

Figura 2.10: Ramo-e-folhas para os dados de dureza de peças de alumínio.

5	0 1 2 3 3 3 4 5 5 5 9
6	3 4 7 9 9
7	0 0 1 2 3 4 7 8
8	2 2 4 5 7
9	5

Todos os gráficos apresentados podem ser usados para variáveis discretas ou contínuas.

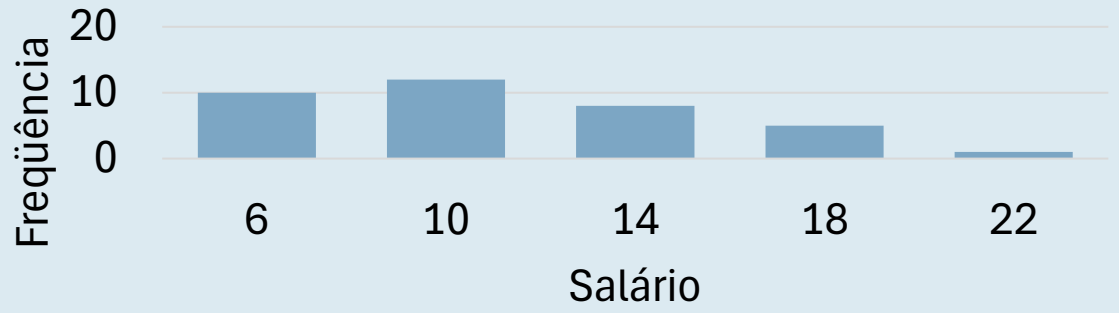
Em alguns casos, para variáveis contínuas é necessário discretizar os dados, ou seja, dividir os dados em classes. Veja o exemplo abaixo:

Tabela 2.6: Distribuição de frequências da variável S, salário dos empregados da seção de orçamentos da Companhia MB.

Classes de salários	Ponto médio si	Freq ni	Porcentagem 100 fi
4,00 ⊢ 8,00	6,00	10	27,78
8,00 ⊢ 12,00	10,00	12	33,33
12,00 ⊢ 16,00	14,00	8	22,22
16,00 ⊢ 20,00	18,00	5	13,89
20,00 ⊢ 24,00	22,00	1	2,78
Total	**—**	**36**	**100,00**

Fonte: Tabela2.4.

Figura 2.6: Gráfico em barras para a variável S: salários.



Existem várias tipos de gráficos. A escolha do gráfico depende tipo do dados e da informação que queremos enfatizar



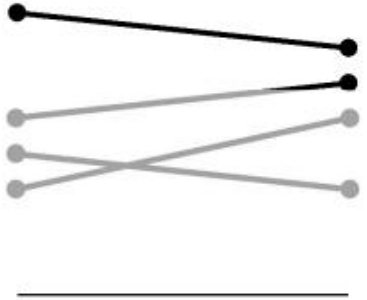
Texto simples



Gráfico de dispersão

	A	B	C
Categoria 1	15%	22%	42%
Categoria 2	40%	36%	20%
Categoria 3	35%	17%	34%
Categoria 4	30%	29%	26%
Categoria 5	55%	30%	58%
Categoria 6	11%	25%	49%

Mapa de calor



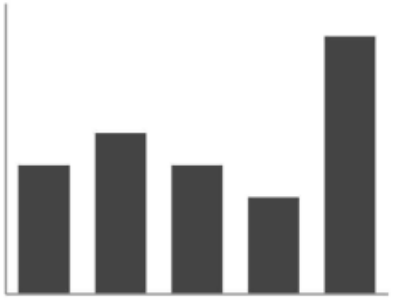
Mapa de inclinação

	A	B	C
Categoria 1	15%	22%	42%
Categoria 2	40%	36%	20%
Categoria 3	35%	17%	34%
Categoria 4	30%	29%	26%
Categoria 5	55%	30%	58%
Categoria 6	11%	25%	49%

Tabela



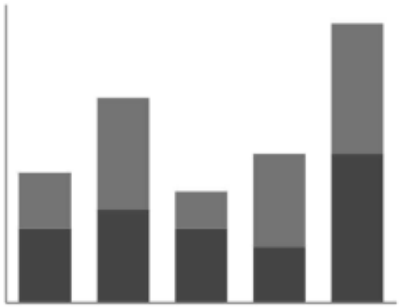
Linha



Barras verticais



Barras horizontais



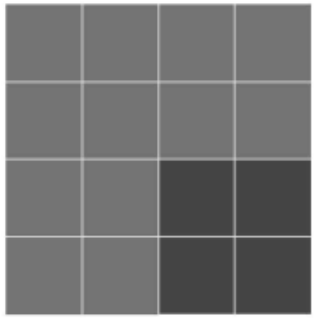
Barras verticais empilhadas



Barras horizontais empilhadas



Cascata



Área quadrada

Exercício (casa). Leia a seção 2.7 do livro (Bussab & Morettin) itens 3 e 4 ou pesquise sobre o tema “Frequências acumuladas”.

Medidas de posição

É um número que representa um conjunto de dados.

- **Moda:** é a realização mais frequente do conjunto de valores
- **Mediana:** é a realização que ocupa a posição central da série (ordenada) de observações.
- **Média (média aritmética):** é a soma das observações dividido pelo número delas.

Medidas de posição

Exemplo: Considere o conjunto de dados $\{4,0,5,1,7,2,3,3,5,1\}$.

- **Moda:**

- **Mediana:**

- **Média:**

Medidas de posição (fórmulas)

Sejam $\{x_1, x_2, \cdots, x_k\}$ um conjunto de dados (distintos ou não).

- **Média:**

$$\overline{\boldsymbol{x}} = \frac{x_1 + x_2 + \cdots + x_k}{k}$$

$$= \frac{n_1 x_1 + n_2 x_2 + \cdots n_j x_j}{k}, \qquad j \leq k \ (n_i = n^{\underline{o}} \ de \ repetições)$$

$$= f_1 x_1 + f_2 x_2 + \cdots f_j x_j, \qquad j \leq k \ (f_i = frequência)$$

- **Mediana:**

Considere o conjunto de dados $\mathrm{X} = \{x_1, x_2, \cdots, x_k\}$ e ordene os dados de forma crescente:

$$x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \cdots \leq x_{(k)}$$

- Se k é par, $md(X) = \dfrac{x_{\left(\frac{k}{2}\right)} + x_{\left(\frac{k}{2}+1\right)}}{2}$

- Se k é ímpar, $md(X) = x_{\left(\frac{k+1}{2}\right)}$

Atividades referentes à aula

Leitura recomendada:

- Bussab & Morettin — Cap. 2: 2.1 a 2.4 (tabelas, gráficos, ramo-e-folhas) e Cap. 3: 3.1 (medidas de posição)
- Montgomery & Runger — Cap. 6: 6.1 a 6.3
- Magalhães & Lima — Cap. 1: 1.2

Atividades referentes à aula (continuação)

Exercícios recomendados:

- Bussab & Morettin — Cap. 2: Problemas 1, 2, 3, 4, 6 e 7; Cap. 3: Problemas 1, 2, 4 e 6
- Magalhães & Lima — Cap. 1: Exercícios 2, 3, 7, 8, 18 e 20; Cap. 4: Exercícios 3, 4, 5 e 11
- Montgomery & Runger — Cap. 6: Exercícios 6.1.6, 6.1.7, 6.1.8, 6.1.9, 6.1.11, 6.2.2, 6.2.4, 6.3.2, 6.3.6 e 6.3.9