CEA055 – Estatística e Probabilidade

Covariância e Correlação

Objetivos da aula:

- Definir e calcular a covariância entre duas variáveis aleatórias.
- Relacionar a covariância à variância da soma de duas variáveis.
- Definir o coeficiente de correlação e interpretar sua força e direção.

Referências:

- Bussab, Morettin. Estatística Básica, 9ed — Cap. 8 (8.4)
- Montgomery, Runger. Applied Statistics..., 7th ed — Cap. 5 (5.4)
- Magalhães, Lima. Noções de Probabilidade e Estatística, 5ed — Cap. 5 (5.2)

Professor: Marcos Goulart Lima

Medindo a associação entre duas variáveis

Na Aula 23, vimos como verificar SE duas v.a. são independentes. Mas quando não são, como medir o QUANTO e em que DIREÇÃO elas variam juntas?

- A covariância é a primeira ferramenta para isso: um número que resume a tendência de X e Y variarem no mesmo sentido, em sentidos opostos, ou sem padrão.

Definição de covariância

A covariância entre X e Y é o valor esperado do produto dos desvios de cada variável em relação à sua média:

$$Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$$

Uma fórmula mais fácil de calcular

Expandindo a definição, chega-se a uma forma equivalente e mais prática para os cálculos:

$$Cov(X, Y) = E(XY) - E(X)\,E(Y)$$

- Essa é a mesma relação usada para a variância: $Var(X) = E(X^2) - [E(X)]^2$, agora estendida para duas variáveis.

Calculando a covariância no exemplo da Aula 23

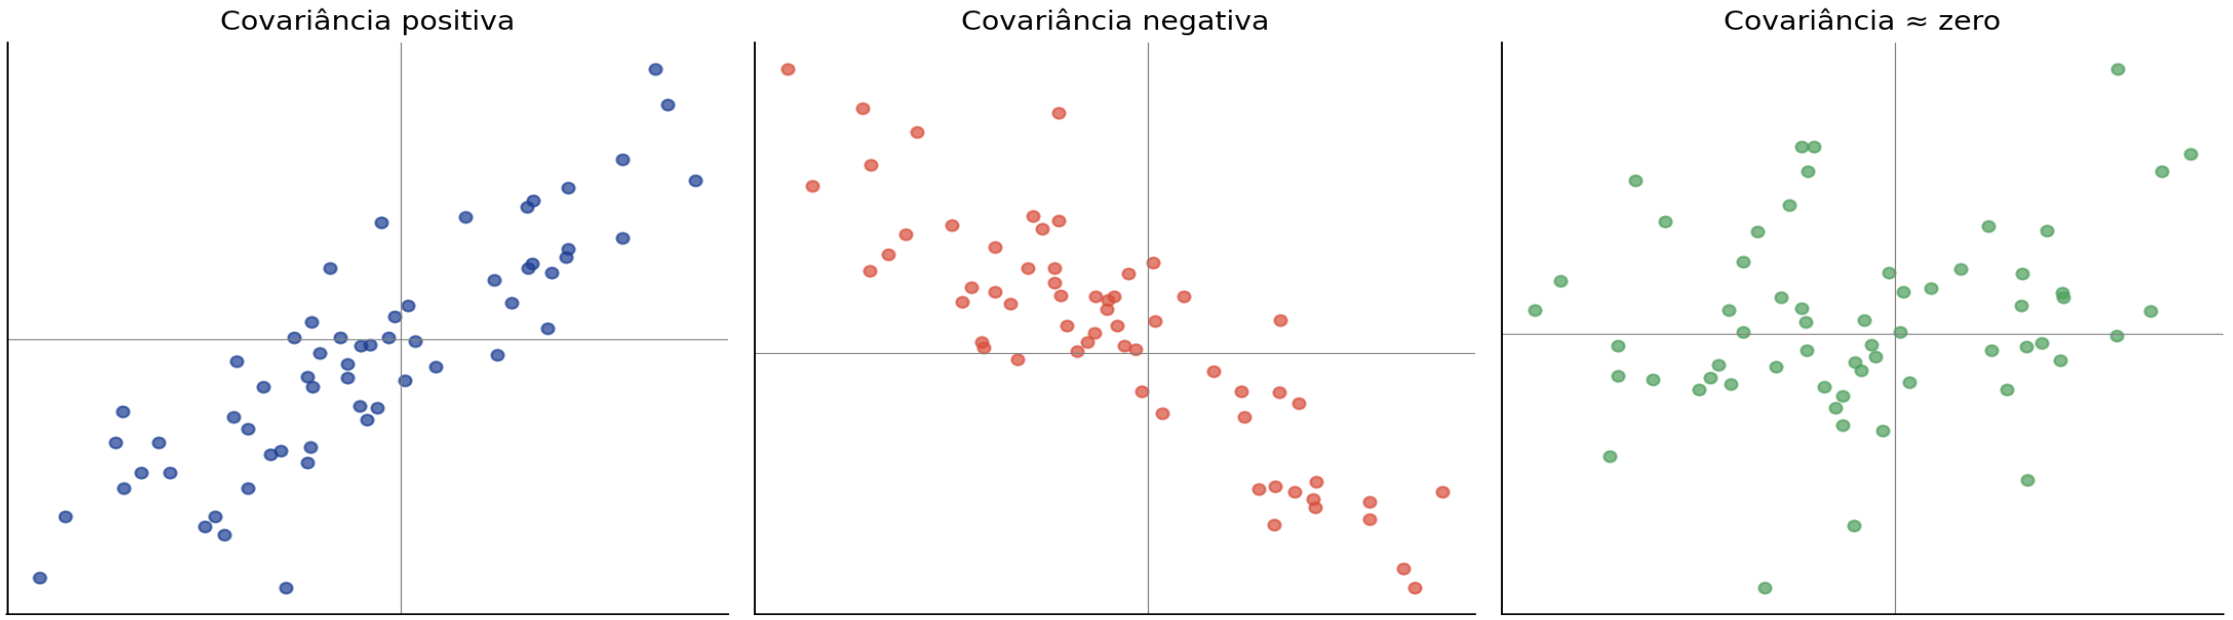
Retomando a central de atendimento (X = chamados recebidos, Y = resolvidos sem escalonamento):

Y \ X	0	1	2	p(y)
0	0.10	0.15	0.10	0.35
1	0.05	0.20	0.40	0.65
p(x)	0.15	0.35	0.50	1,00

Já calculamos: E(X) = 1,35; E(Y) = 0,65; E(XY) = 1,00. Cov(X,Y) = 1,00 − (1,35×0,65) = 1,00 − 0,8775 = 0,1225.

Interpretando o sinal da covariância

O SINAL de Cov(X,Y) indica a direção da associação linear entre X e Y:



No nosso exemplo, Cov = 0,1225 > 0: X e Y tendem a crescer juntas.

Covariância zero ≠ independência

- Se X e Y são independentes, então Cov(X,Y) = 0 (não há associação linear a medir).
- MAS a recíproca é falsa: Cov(X,Y) = 0 não garante independência — pode haver uma relação não linear forte, que a covariância não enxerga.
- Exemplo clássico: se $Y = X^2$ e X é simétrica em torno de 0, Cov(X,Y) pode ser exatamente zero, mesmo Y sendo completamente determinada por X.

Conclusão: covariância mede apenas associação LINEAR — relações em "U" ou curvas podem passar despercebidas.

Por que a covariância importa: variância da soma

Já anunciamos essa fórmula na Aula 23 — agora com a covariância definida, ela fica completa:

$$Var(X + Y) = Var(X) + Var(Y) + 2\,Cov(X, Y)$$

- Se Cov(X,Y) = 0 (inclusive quando são independentes), recuperamos Var(X+Y) = Var(X) + Var(Y).
- Se Cov(X,Y) > 0, a soma X+Y é MAIS variável do que a soma das variâncias individuais sugeriria.

O problema da escala

- A covariância depende das UNIDADES de X e Y — isso dificulta comparar a “força” da associação entre pares de variáveis diferentes.
- Exemplo: Cov(altura em cm, peso em kg) terá um valor numérico diferente de Cov(altura em metros, peso em kg) — mesma relação, escala diferente.
- Precisamos de uma versão “padronizada” da covariância, que não dependa da escala — é isso que o coeficiente de correlação resolve.

Coeficiente de correlação ρ

Padronizamos a covariância dividindo pelos desvios padrão de X e de Y:

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

- Essa razão elimina as unidades de medida: ρ é sempre um número puro, entre −1 e +1.
- $-1 \leq \rho(X,Y) \leq +1$, sempre — essa é a grande vantagem sobre a covariância.

Interpretando o coeficiente de correlação

- $\rho = +1$: associação linear POSITIVA perfeita (todos os pontos numa reta crescente).
- $\rho = -1$: associação linear NEGATIVA perfeita (reta decrescente).
- $\rho = 0$: nenhuma associação LINEAR (mas pode haver associação não linear, como na Aula 23).
- Quanto mais próximo de ±1, mais forte a associação linear; quanto mais próximo de 0, mais fraca.
- Valores intermediários (ex.: $\rho = 0{,}3$ ou $\rho = -0{,}7$) são os mais comuns na prática — raramente vemos ρ exatamente ±1 ou 0.

Calculando ρ no exemplo da central de atendimento

Já temos: Cov(X,Y) = 0,1225. Precisamos agora de Var(X) e Var(Y).

- $\text{Var}(X) = E(X^2) - [E(X)]^2 = 2{,}35 - 1{,}35^2 = 0{,}5275 \rightarrow \sigma_x = \sqrt{0{,}5275} = 0{,}726$.
- $\text{Var}(Y) = E(Y^2) - [E(Y)]^2 = 0{,}65 - 0{,}65^2 = 0{,}2275 \rightarrow \sigma_y = \sqrt{0{,}2275} = 0{,}477$.
- $\rho(X,Y) = 0{,}1225 / (0{,}726 \times 0{,}477) = 0{,}1225 / 0{,}3465 = 0{,}354$.

Interpretação: correlação positiva moderada — mais chamados recebidos tende a vir com mais resoluções sem escalonamento, mas a relação não é muito forte.

Cuidado: correlação não é causalidade

- Duas variáveis correlacionadas podem estar associadas por uma TERCEIRA variável, sem que uma cause a outra.
- Exemplo clássico: vendas de sorvete e afogamentos são correlacionados positivamente — mas o calor do verão causa ambos, um não causa o outro.
- Antes de concluir causalidade a partir de uma correlação, é preciso um desenho experimental adequado (ex.: estudo controlado), não apenas dados observacionais.

Resumo da aula

- Covariância: $Cov(X,Y) = E(XY) - E(X)E(Y)$ — mede direção da associação linear, mas depende da escala.
- Coeficiente de correlação: $\rho = Cov(X,Y)/(\sigma_x\sigma_y)$ — versão padronizada, sempre entre −1 e +1.
- $Cov(X,Y) = 0$ (ou $\rho = 0$) não implica independência — apenas ausência de associação LINEAR.
- Correlação mede associação, não causalidade.

Próximas aulas: usaremos essas ideias para construir um modelo que PREVÊ uma variável a partir da outra — a regressão linear.

Atividades referentes à aula

Leitura recomendada:

- Bussab & Morettin — Cap. 8: 8.4
- Montgomery & Runger — Cap. 5: 5.4
- Magalhães & Lima — Cap. 5: 5.2

Exercícios recomendados:

- Usando a tabela do Exemplo 2 da Aula 23 (inspeção de peças), calcule Cov(X,Y) e ρ(X,Y).
- Explique com suas palavras por que Cov(X,Y)=0 não garante independência, usando um exemplo próprio.