



UFOP

Universidade Federal
de Ouro Preto

Correlação Linear e Modelo de Regressão Simples

Objetivos da aula:

- Calcular e interpretar o coeficiente de correlação linear amostral r .
- Compreender o modelo de regressão linear simples e suas suposições.
- Estimar os parâmetros do modelo pelo método dos mínimos quadrados.

Referências:

- Bussab, Morettin. Estatística Básica, 9ed — Cap. 16 (16.1, 16.2)
- Montgomery, Runger. Applied Statistics..., 7th ed — Cap. 11 (11.2, 11.3, 11.8)
- Magalhães, Lima. Noções de Probabilidade e Estatística, 5ed — Cap. 9 (9.5)



UFOP

Universidade Federal
de Ouro Preto

De associação a previsão

Na Aula 25, medimos a FORÇA da associação linear entre duas variáveis com p . Mas ainda não temos um MODELO que descreva essa relação.

- Hoje damos o passo seguinte: ajustar uma reta que resuma a relação entre X e Y , e que permita PREVER Y a partir de X .
- Exemplo que usaremos: X = investimento em publicidade (mil R\$), Y = vendas (mil unidades), em 8 lojas de uma rede.




UFOP

Universidade Federal
de Ouro Preto

Correlação Linear e Regressão Simples

O primeiro passo: o diagrama de dispersão

Antes de qualquer cálculo, sempre visualize os dados:





UFOP

Universidade Federal
de Ouro Preto

Coeficiente de correlação amostral r

Com uma amostra de n pares (x_i, y_i) , estimamos ρ (Aula 25) pelo coeficiente amostral r :

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$



UFOP

Universidade Federal
de Ouro Preto

Interpretando r

- Mesma lógica de p (Aula 25): $-1 \leq r \leq +1$, sinal indica direção, magnitude indica força da associação LINEAR.
- r é uma ESTIMATIVA de p calculada a partir de uma amostra específica — outra amostra daria um r ligeiramente diferente.
- Faixas usadas informalmente: $|r| > 0,7$ costuma ser considerado forte; entre 0,3 e 0,7, moderado; abaixo de 0,3, fraco (não são regras rígidas).



UFOP

Universidade Federal
de Ouro Preto

Calculando r no exemplo da publicidade

Dados ($n=8$): $X = 2,3,4,5,6,7,8,9$ (mil R\$); $Y = 11,14,15,18,20,21,25,27$ (mil unidades).

- $\bar{X} = 5,5$; $\bar{Y} = 18,875$.
- $S_{xx} = \sum(x_i - \bar{X})^2 = 42,0$; $S_{yy} = \sum(y_i - \bar{Y})^2 = 210,875$; $S_{xy} = \sum(x_i - \bar{X})(y_i - \bar{Y}) = 93,5$.
- $r = 93,5 / \sqrt{42,0 \times 210,875} = 93,5 / 94,10 = 0,994$.

Interpretação: correlação linear POSITIVA muito forte — mais investimento em publicidade está fortemente associado a mais vendas.



UFOP

Universidade Federal
de Ouro Preto

O modelo de regressão linear simples

Um passo além da correlação: propor um modelo que descreve Y em função de X:

$$Y_i = \alpha + \beta X_i + e_i$$

- α (intercepto) e β (inclinação) são parâmetros desconhecidos, a estimar a partir dos dados.
- e_i é o erro aleatório — tudo que a reta não explica (variação individual de cada ponto).



UFOP

Universidade Federal
de Ouro Preto

Suposições do modelo

- X é considerada fixa (controlada), sem erro de medida — só Y tem componente aleatório.
- Os erros e_i têm média zero: $E(e_i|x) = 0$ — a reta captura a tendência central corretamente.
- Os erros têm variância constante em torno da reta, para qualquer valor de X (homocedasticidade).
- Os erros não são correlacionados entre si.

Vamos verificar essas suposições na prática, com gráficos de resíduos, na Aula 27.



UFOP

Universidade Federal
de Ouro Preto

Interpretando α e β

- α (intercepto): valor esperado de Y quando $X = 0$. Nem sempre tem interpretação prática direta (ex.: publicidade = 0 pode estar fora da faixa observada).
- β (inclinação): o quanto Y muda, EM MÉDIA, para cada aumento de 1 unidade em X.
- No nosso exemplo: se $\beta \approx 2,2$, cada mil R\$ a mais em publicidade está associado a, em média, 2,2 mil unidades a mais vendidas.



UFOP

Universidade Federal
de Ouro Preto

O método dos mínimos quadrados

- Precisamos escolher os “melhores” valores de α e β para a reta. Mas “melhor” segundo qual critério?
- Ideia: minimizar a soma dos quadrados das distâncias verticais entre os pontos observados e a reta (os resíduos).
- Por que ao quadrado? Para que desvios positivos e negativos não se cancelem, e para penalizar mais os erros grandes.

Esse critério tem solução matemática exata, dada pelas fórmulas a seguir.



UFOP

Universidade Federal
de Ouro Preto

Os estimadores de mínimos quadrados

A inclinação e o intercepto que minimizam a soma dos quadrados dos resíduos são:

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$$



UFOP

Universidade Federal
de Ouro Preto

Ajustando a reta ao exemplo da publicidade

Já temos $S_{xx} = 42,0$ e $S_{xy} = 93,5$ (slide anterior). Calculamos:

- $\hat{\beta} = S_{xy} / S_{xx} = 93,5 / 42,0 = 2,226$.
- $\hat{\alpha} = \bar{Y} - \hat{\beta} \cdot \bar{X} = 18,875 - 2,226 \times 5,5 = 18,875 - 12,244 = 6,631$.

Reta ajustada: $\hat{Y} = 6,631 + 2,226 \cdot X$



UFOP


Universidade Federal
de Ouro Preto

Correlação Linear e Regressão Simples

A reta ajustada

$$\hat{Y} = 6,631 + 2,226 \cdot X$$

- Cada mil R\$ investido em publicidade está associado a um aumento médio de 2.226 unidades vendidas.
- O intercepto (6,631) seria a venda esperada sem publicidade nenhuma — mas atenção: $X=0$ está fora da faixa observada (2 a 9), então essa leitura deve ser vista com cautela.





UFOP

Universidade Federal
de Ouro Preto

Como r e $\hat{\beta}$ se relacionam

- r e $\hat{\beta}$ sempre têm o MESMO SINAL — ambos vêm do mesmo numerador S_{xy} .
- Mas são coisas diferentes: r não tem unidade (é adimensional); $\hat{\beta}$ tem unidade de Y por unidade de X (aqui, mil unidades vendidas por mil R\$ investido).
- Relação exata: $\hat{\beta} = r \times (S_y/S_x)$, em que S_y e S_x são os desvios padrão amostrais de Y e X.

Em resumo: r mede a FORÇA da relação; $\hat{\beta}$ mede o IMPACTO prático de X sobre Y, em suas próprias unidades.



UFOP

Universidade Federal
de Ouro Preto

Usando o modelo para prever

- Com a reta ajustada, podemos prever Y para um novo valor de X , dentro da faixa observada.
- Exemplo: quanto esperamos vender com $X = 6,5$ mil R\$ de publicidade?
- $\hat{Y} = 6,631 + 2,226 \times 6,5 = 6,631 + 14,469 = 21,10$ mil unidades.

Essa previsão é uma estimativa da média de Y para $X=6,5$ — vendas reais variam em torno desse valor, devido ao erro aleatório e_i .



UFOP

Universidade Federal
de Ouro Preto

Cuidado com a extrapolação

- O modelo só foi validado dentro da faixa observada de X (no exemplo, de 2 a 9 mil R\$).
- Prever fora dessa faixa (ex.: $X = 50$ mil R\$) é arriscado — não temos garantia de que a relação linear continua válida tão longe dos dados observados.
- Investimentos muito altos podem ter retornos decrescentes (saturação de mercado) — um padrão que uma reta ajustada a dados pequenos não conseguiria capturar.

Regra prática: use o modelo para interpolar (dentro da faixa), com cautela redobrada ao extrapolar.



UFOP

Universidade Federal
de Ouro Preto

Resumo da aula

- r mede a força e direção da associação linear entre X e Y , numa amostra.
- O modelo $Y = \alpha + \beta X + e$ propõe uma relação linear entre as duas variáveis, com erro aleatório.
- O método dos mínimos quadrados fornece as fórmulas de $\hat{\alpha}$ e $\hat{\beta}$ que melhor ajustam a reta aos dados.
- A reta ajustada permite interpolar previsões de Y , com cautela ao extrapolar.

Próxima aula: como avaliar se o modelo ajustado é realmente bom, usando resíduos e o coeficiente de determinação R^2 .



UFOP

Universidade Federal
de Ouro Preto

Atividades referentes à aula

Leitura recomendada:

- Bussab & Morettin — Cap. 16: 16.1, 16.2
- Montgomery & Runger — Cap. 11: 11.2, 11.3, 11.8
- Magalhães & Lima — Cap. 9: 9.5

Exercícios recomendados:

- Usando os mesmos dados do exemplo, calcule a previsão de vendas para $X = 4,5$ mil R\$.
- Colete (ou invente) 6 pares de dados de duas variáveis do seu cotidiano e ajuste uma reta de mínimos quadrados.