

CEA055 – Estatística e Probabilidade

Lista de Exercícios 27 – Regressão B (avaliação do modelo: ANOVA, R^2 e resíduos)

Aviso: esta lista de exercícios foi elaborada com o auxílio da IA Claude (Anthropic). Os problemas são originais (não copiados de nenhum livro-texto). As fórmulas e convenções usadas foram conferidas contra a bibliografia da disciplina. Revise as respostas com atenção – como em qualquer material gerado com apoio de IA, pode haver imprecisões.

Parte 1 – Revisão de conceitos

1. O que representam $SQTot$, $SQReg$ e $SQRes$ na decomposição da variabilidade total de y ? Como eles se relacionam (escreva a fórmula)?
2. Classifique cada afirmação como Verdadeira ou Falsa, **justificando** em uma frase:
 - (a) $R^2 = SQReg/SQTot$ mede a proporção da variabilidade total de y que é "explicada" pelo modelo de regressão.
 - (b) Um R^2 próximo de 1 significa necessariamente que existe uma relação de causa e efeito entre x e y .
 - (c) A estatística F da tabela ANOVA testa se $\beta = 0$ (ou seja, se o modelo de regressão é útil, comparado ao modelo trivial "usar só a média de y ").
3. Por que analisar o padrão dos resíduos (por exemplo, num gráfico de resíduos contra x) é importante para avaliar se o modelo linear é adequado, além de simplesmente olhar para o valor de R^2 ?

Parte 2 – Resolução (fórmulas e cálculos)

Retome os dados da Aula 26 (horas de estudo x e nota y de 5 alunos), cuja reta ajustada foi $\hat{y} = 41,5 + 3,75x$, com resíduos 1,0; -1,5; 1,0; -1,5; 1,0 (para $x = 2, 4, 6, 8, 10$, respectivamente).

4. Calcule $SQTot = \sum (y_i - \bar{y})^2$ (lembrando que $\bar{y} = 64$).
5. Usando os resíduos já dados, calcule $SQRes = \sum \hat{e}_i^2$.
6. Calcule $SQReg = SQTot - SQRes$, e a partir daí calcule $R^2 = SQReg/SQTot$. Esse valor bate com o r^2 que você calculou na Aula 26 (a partir do coeficiente de correlação)?
7. Monte a tabela ANOVA completa para esses dados: para cada fonte de variação (Regressão, Resíduo, Total), calcule os graus de liberdade, a soma de quadrados (SQ), o quadrado médio (QM) e, para a linha de Regressão, a estatística F .

Parte 3 – Desafio

Desafio

9. Um novo conjunto de dados relaciona horas semanais de exercício físico (x) com uma métrica de condicionamento (y) de 6 pessoas:

$$x : 1, 2, 3, 4, 5, 6 \quad y : 10, 14, 20, 22, 24, 24$$

- (a) Ajuste a reta de mínimos quadrados (calcule $\hat{\beta}$ e $\hat{\alpha}$).
- (b) Calcule a tabela ANOVA completa (SQTot, SQReg, SQRes, graus de liberdade, QM e F) para esse ajuste.
- (c) Calcule R^2 . Compare com o R^2 obtido no Exercício 6 (dados de horas de estudo x nota, da Aula 26) – qual dos dois modelos "explica" proporcionalmente mais da variabilidade de y ?
- (d) Calcule os resíduos $\hat{e}_i = y_i - \hat{y}_i$ para os 6 pontos, na ordem de x crescente. Observando os **sinais** dos resíduos em sequência, existe algum padrão sistemático (não aleatório)? O que esse padrão sugere sobre a adequação do modelo linear para esses dados especificamente (dica: pense se o crescimento de y parece "desacelerar" à medida que x aumenta)?

Parte 4 – Desafio bônus (opcional, não vale nota)

10. Exercício opcional, para quem quiser praticar programação. Não precisa instalar nada – roda direto no [Google Colab](#).

Vamos confirmar os cálculos do Desafio (Exercício 9) e visualizar o padrão dos resíduos.

- (a) Ajuste o modelo e calcule a tabela ANOVA "na mão" (com `numpy`), reaproveitando a mesma lógica das aulas anteriores:

```
import numpy as np

x = np.array([1, 2, 3, 4, 5, 6])
y = np.array([10, 14, 20, 22, 24, 24])
n = len(x)

xbar, ybar = x.mean(), y.mean()
beta = np.sum((x - xbar) * (y - ybar)) / np.sum((x - xbar)**2)
alpha = ybar - beta * xbar

yhat = alpha + beta * x
residuos = y - yhat

SQTot = np.sum((y - ybar)**2)
SQRes = np.sum(residuos**2)
SQReg = SQTot - SQRes
R2 = SQReg / SQTot

QMReg = SQReg / 1
QMRes = SQRes / (n - 2)
F = QMReg / QMRes

print("beta:", beta, "alpha:", alpha)
print("R2:", R2, "F:", F)
```

- (b) Compare os valores obtidos com os calculados manualmente no Desafio. Eles batem?
- (c) Construa um gráfico de resíduos (resíduo no eixo y , valor de x no eixo x), com uma linha horizontal em zero para referência:

```
import matplotlib.pyplot as plt

plt.scatter(x, residuos)
plt.axhline(0, color="red", linestyle="--")
plt.xlabel("x (horas de exercicio)")
plt.ylabel("residuo")
plt.show()
```

O padrão visual (os pontos formam uma curva sistemática, subindo e depois descendo, em vez de estarem espalhados aleatoriamente ao redor de zero) confirma a suspeita de não linearidade discutida no item (d) do Desafio?